



UNIVERSIDAD DE CHILE

FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS

DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN

EXTENSIÓN DE FILTRO DE KALMAN DE APROXIMACIÓN NO LINEAL PARA LA
DETECCIÓN DE OBJETOS ASTRONÓMICOS

TESIS PARA OPTAR AL TÍTULO DE INGENIERA CIVIL EN COMPUTACIÓN

PALOMA PÉREZ GARCÍA

PROFESOR GUÍA:

SR. PABLO ESTEVEZ VALENCIA

MIEMBROS DE LA COMISIÓN:

SR. BENJAMÍN BUSTOS

SR. ZZZ ZZZ ZZZ

SR. ZZ ZZ ZZ

SR. ZZZ ZZZ ZZZ

SANTIAGO DE CHILE
DICIEMBRE 2018

Resumen Ejecutivo

Agradecimientos

Paloma Pérez García

Índice general

Resumen Ejecutivo	I
Agradecimientos	III
1. Introducción	1
1.1. Motivación	1
1.2. Trabajo anterior	2
1.3. Organización de la tesis	2
2. Antecedentes	3
2.1. Supernova	3
2.2. High Cadence Transient Survey: HiTS	4
2.3. ¿Qué se entiende por <i>linealidad</i> ?	5
2.4. El filtro de Kalman	5
2.4.1. Filtro de Kalman Básico	6
2.4.2. Filtro de Kalman de Máxima Correntropía	8
2.4.3. Filtro de Kalman Unscented	10
2.5. Ambiente de prueba: NLHPC	13
3. Refactoring	14
3.1. Ejecución de la rutina	14
3.2. Manejo de datos de entrada	14
3.2.1. Lectura y preparación de imágenes	15
3.2.2. Resultados guardados	16
3.3. Determinación de flujos	16
3.4. Filtros originales	16
3.4.1. Filtro básico	16
3.4.2. Filtro de máxima correntropía	16
3.5. Detección de candidatos	16

4. Resultados	17
5. Conclusiones	18
Capítulo Adicional que no es apéndice	19
Apéndices	20
A . Refactoring	20
A .1. Archivo de entrada: configuración de paths	20
A .2. Modelo de archivo de almacenamiento de resultados	20
B . Unit-tests	20
Referencias	21

Índice de cuadros

Índice de figuras

2.1. Representación simple y no a escala de la estructura de una estrella masiva previo a su supernova. Los elementos más pesados se alojan en el centro, mientras que los más livianos, como el hidrógeno o el helio lo hacen en la capa más externa.	3
2.2. Curvas típicas de supernovas I y II.	4
2.3. Diagrama que ilustra la evolución del brillo de una supernova en términos de luminosidad solar (L_{\odot}) durante días. Se resalta el fenómeno de shock breakout apenas comienza el incremento de la luminosidad de la supernova. Esta imagen fue publicada en la página de la NASA destacando la primera vez que un evento como este es <i>capturado</i> en la banda visible (por el telescopio espacial Kepler).	5
2.4.	6
2.5. Representación del proceso de predicción (obtención de cantidades a priori) de las cantidades $\hat{x}_{k k-1}$ y $P_{k k-1}$; y de corrección (estimación a posteriori) para obtener las cantidades $\hat{x}_{k+1 k}$ y $P_{k+1 k}$	8
2.6. Representación del funcionamiento del filtro UKF. En esta oportunidad se hace uso de la función f y h para obtener las transformaciones $x_{k-1} \rightarrow x_k$ y $x_k \rightarrow z_k$. Esto se logra con la evaluación de de los $2N+1$ puntos generados durante la etapa de predicción (y posteriormente en la etapa de corrección).	11

1 | Introducción

1.1. Motivación

La astronomía es uno de los campos científicos que más se ha visto afectado por el rápido crecimiento en la generación de datos debido al fuerte desarrollo de nuevas tecnologías de la información y de nuevos instrumentos destinados a la observación. Este crecimiento ha gatillado un aumento importante en la demanda de una nueva generación de métodos que puedan procesar esta oleada de información o big data astronómico.

Ejemplos de proyectos que actualmente producen una gran cantidad de datos a través de telescopios en diferentes partes del mundo son: el Panoramic Survey Telescope and Rapid Response System (Pan-STARRS), el Visible and Infrared Survey Telescope (VISTA), el VLT Survey Telescope (VST), el Dark Energy Camera Legacy Survey (DECaLS) y el Hyper Suprime-Cam Subaru Strategic Program (HSC SSP). Estos surveys están caracterizados por un amplio *étendue* (producto entre el área del espejo de un telescopio y su ángulo sólido proyectado en el cielo).

En el futuro, telescopios como el Large Synoptic Survey Telescope (LSST) [6] (que entrará en funcionamiento a mediados del 2022) continuarán revolucionando la era del big data en astronomía con *etendues* y cámaras CCD mucho más grandes de lo que hasta el día de hoy se utiliza. En particular se espera que el LSST produzca un número de alertas trasientes (avisos de objetos encontrados y su consecuente seguimiento) del orden del millón cada noche. La capacidad de detectar nuevos objetos de interés dependerá de la calidad de los datos y de los algoritmos de tiempo real destinados a generar las alertas mencionadas.

Actualmente existen sondeos como el High Cadence Transient Survey (HiTS) [3] cuya finalidad es la búsqueda de fenómenos trasientes rápidos con escalas de tiempo que van desde las horas a días, utilizando secuencias de observaciones de la cámara DECam del telescopio Blanco (en Cerro Tololo) para la detección y posterior reporte de objetos candidatos a supernova. En su trabajo proponen un método de detección de potenciales candidatos a supernova a través de la discriminación de píxeles que involucren un incremento trasiente de intensidad.

Esta discriminación comienza con la determinación del flujo a través de la intensidad de los píxeles que puedan corresponder a una estrella y a la variación de cada uno de ellos usando métodos iterativos de filtrado en secuencias de imágenes de largo arbitrario. Los filtros usados en HiTS corresponden a miembros de una familia de filtros conocidos como *filtros de Kalman*. En particular se hace uso de los filtros de Kalman básico [5] y de correntropía máxima [2].

...

En el presente trabajo se pretende desarrollar un nuevo módulo de filtro de Kalman que sea robusto a sistemas no-lineales para la detección de potenciales candidatos a supernova, para posteriormente ser embebido en un programa que pueda funcionar en línea generando alarmas de detección. Por otro lado se busca implementar un software que contenga los métodos de filtrados originales (versiones clásica y de máxima correntropía del filtro de Kalman) a través de un refactoring del programa base. Paralelamente, se desea encontrar rangos apropiados para los parámetros requeridos en cada caso.

1.2. Trabajo anterior

1.3. Organización de la tesis

Posteriormente, en el capítulo 4, se describen los resultados obtenidos de las pruebas descritas en el capítulo anterior comparando tasas de verdaderos positivos y falsos negativos, así como analizando las estadísticas de los grupos de píxeles candidatos (tanto descartados como confirmados).

Finalmente las conclusiones, contenidas en el capítulo 5, resumen el aprendizaje obtenido durante este trabajo así como los resultados relevantes obtenidos durante las pruebas establecidas. Además se plantean nuevas líneas de trabajo futuro.

2 | Antecedentes

2.1. Supernova

Una supernova corresponde a un evento estelar con el que finaliza una estrella masiva (aquellas que en su proceso de formación poseen una masa superior a 10 masas solares¹). Al ya no contar con combustible necesario para llevar a cabo reacciones nucleares que puedan contrarrestar su propia gravedad (su núcleo ya no puede formar elementos más pesados que el hierro o el níquel), y si la presión degenerada de los electrones del plasma de la estrella no es suficiente para soportar este peso, la estrella se contrae abruptamente incrementando el peso de su centro a 10^{10} K.




Figura 2.1: Representación simple y no a escala de la estructura de una estrella masiva previo a su supernova. Los elementos más pesados se alojan en el centro, mientras que los más livianos, como el hidrógeno o el helio lo hacen en la capa más externa.

Debido al aumento de temperatura, los electrones del núcleo adquieren energía cinética suficiente para escapar, desapareciendo así la presión que ejercían hacia el exterior. Finalmente el núcleo colapsa liberando energía gravitacional y con ella las más externas de la estrella son expulsadas en una gran explosión. Este fenómeno se denomina *supernova* e implica un aumento repentino del

¹ $M_{\odot} = (1.98847 \pm 0.00007) \times 10^{30}$ Kg

brillo de una estrella, incrementando su brillo en un factor de 10^8 veces, pudiendo incluso ser más brillante que la galaxia que la alberga.

En general la variación de la luminosidad de una supernova corresponde a una curva que crece rápidamente los primeros días (u horas), alcanzando un máximo, para luego decaer. A partir de la fisonomía de esta curva, es posible distinguir dos tipos de supernova: tipo I y tipo II. Las primeras presentan un decaimiento continuo una vez alcanzado el máximo, mientras que las segundas presentan dos caídas: una inmediatamente después de su máximo y otra una vez finalizado un periodo de luminosidad constante (figura 2.2). Otra forma de diferenciarlas es la presencia de trazas de hidrógeno en los espectros de estas: las supernovas de tipo I practicamente no presentan hidrógeno (líneas de absorción distintivas) a diferencia de las de tipo II.




Figura 2.2: Curvas típicas de supernovas I y II.

2.2. High Cadence Transient Survey: HiTS

El High Cadence Transient Survey (desde ahora, HiTS) es un survey cuyo objetivo principal es el detectar y seguir fenómenos transientes estelares en escalas de tiempo que van desde horas a días, con especial atención a fases tempranas de explosiones de supernovas (primeras horas): el objetivo original de HiTS corresponde a la detección de un fenómeno llamado *shock breakout* (SBO), un fenómeno que ocurre inmediatamente después del colapso del núcleo de una estrella roja supergigante (una de las posibles etapas finales de una estrella masiva antes de *explotar*). Ver figura 2.3².

² $L_{\odot} = 3.828 \times 10^{26} \text{ W}$




Figura 2.3: Diagrama que ilustra la evolución del brillo de una supernova en términos de luminosidad solar (L_{\odot}) durante días. Se resalta el fenómeno de shock breakout apenas comienza el incremento de la luminosidad de la supernova. Esta imagen fue publicada en la página de la NASA destacando la primera vez que un evento como este es *capturado* en la banda visible (por el telescopio espacial Kepler).

HiTS utiliza la Dark Energy Camera (DECam) para la obtención de sus imágenes. Esta cámara se encuentra montada en el Telescopio Blanco del Observatorio de Cerro Tololo (CTIO) en la región de Coquimbo, Chile.

2.3. ¿Qué se entiende por *linealidad*?

2.4. El filtro de Kalman

La evolución determinística de un sistema físico en el tiempo es conocido sí el estado del sistema es medido con absoluta precisión en cada instante de tiempo (i.e. en un entorno donde es posible despreciar fenómenos cuánticos). Sin embargo toda medición está sujeta a incertezas finitas. Para sistemas los cuales son observados entre intervalos prolongados de tiempo, se prevee que las diferencias entre los estados estimados y los medidos se incrementen con el tiempo. Para la obtención de predicciones lo más confiables posible se requiere que el sistema sea regularmente monitoreado y sus estados estimados futuros puedan ser considerados confiables en un lapso de tiempo en apropiado.

Los filtros de Kalman son métodos que proveen un trade-off entre los valores esperados del estado actual de un sistema y las mediciones que proporcionan información de su estado real. La aplicación de un filtro de Kalman está pensada como un proceso de dos fases:





Figura 2.4: ...

1. **Fase predictiva:** Una estimación del estado actual del sistema que se basa en la estimación del estado previo o último estado. Esta predicción se denomina usualmente como estado estimado *a priori*.
2. **Fase correctiva:** La estimación del estado *a priori* es corregida con una medida actual para refinar la aproximación. Esta mejora se denomina *aproximación a posteriori*.

Típicamente estas fases de predicción y corrección se van alternando mientras se estudie el comportamiento físico de algún sistema.

2.4.1. Filtro de Kalman Básico

El filtro de Kalman Básico asume un comportamiento de sistema lineal y que las mediciones y las predicciones siguen una distribución Gaussiana.

A continuación se describen las componentes más importantes en el desarrollo matemático del filtro:

- F_k : Matriz de transición de estado, de dimensiones $N \times N$ (N es el número de variables de estado).
- H_k : Matriz de transformación de estado a medición, $K \times N$ (K corresponde a las mediciones realizadas en un instante k de una variable de estado).

- Q_k : Matriz de covarianza del ruido del proceso ($N \times N$).
- R_k : Matriz de covarianza del ruido de las mediciones ($K \times K$).
- B_k : Matriz de control de entrada (contiene alteraciones que se querían agregar al sistema de manera deliberada, por ejemplo, como la condición de parada de un vehículo en movimiento). Esta matriz es de dimensiones $N \times L$, donde L es la dimensión del vector de control de entrada u_k .

A continuación se hará uso de la notación en subíndices $m|n$, en las estimaciones de estado y covarianzas, para explicitar al instante de tiempo al cual pertenecen: m ; y al instante de tiempo de donde se extrae la información: n .

En el instante $k - 1$, se obtienen dos cantidades

- $\hat{x}_{k|k-1}$: Estado estimado *a priori*.
- $P_{k|k-1}$: Matriz de covarianza *a priori*.

Luego, en la fase de corrección se calculan:

- $\hat{x}_{k|k}$: Estado estimado *a posteriori*.
- $P_{k|k}$: Matriz de covarianza *a posteriori*.

Con estas variables, podemos describir las ecuaciones que explican la evolución del proceso de este algoritmo:

1. Fase predictiva:

Estimación de estado y matriz de covarianza *a priori*.

$$\hat{x}_{k|k-1} = F_k \hat{x}_{k-1|k-1} + B_k u_k \quad (2.1)$$

$$P_{k|k-1} = F_k P_{k-1|k-1} F_k^T + Q_k \quad (2.2)$$

2. Fase correctiva:

Estimación de estado y matriz de covarianza *a posteriori*.

$$\hat{z}_k = H_k \hat{x}_{k|k-1} \quad (2.3)$$

$$\tilde{z}_k = z_k - \hat{z}_k \quad (2.4)$$

La ecuación 2.4 describe la obtención de un residuo de la diferencia entre la predicción y la medida z_k . Posteriormente se calcula la matriz de covarianza entre residuos (2.5), con la que se calcula la ganancia de Kalman (ecuación 2.6).

$$S_k = H_k P_{k|k-1} H_k^T + R_k \quad (2.5)$$

$$K_k = P_{k|k-1} H_k^T S_k^{-1} \quad (2.6)$$

Con la ganancia de Kalman calculada, se actualiza el valor de la estimación de estado (2.7) y matriz de covarianza a posteriori (2.8).

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \tilde{z}_k \quad (2.7)$$

$$P_{k|k} = (I_N - K_k H_k) P_{k|k-1} \quad (2.8)$$




Figura 2.5: Representación del proceso de predicción (obtención de cantidades a priori) de las cantidades $\hat{x}_{k|k-1}$ y $P_{k|k-1}$; y de corrección (estimación a posteriori) para obtener las cantidades $\hat{x}_{k+1|k}$ y $P_{k+1|k}$.

2.4.2. Filtro de Kalman de Máxima Correntropía

El filtro de Kalman basado en correntropía máxima [1], difiere del filtro de Kalman tradicional (básico) en que no asume gaussianidad en las observaciones, considerando casos en que una señal puede ser perturbada por pulsos de ruido que sigan una distribución de cola pesada, y en esta oportunidad se utiliza el *criterio de correntropía máxima* para el proceso de corrección.

Recordando que la correntropía es una medida de similitud entre dos variables aleatorias, supongamos, $X, Y \in \mathbb{R}$ con una distribución conjunta $F_{XY}(x, y)$, definimos la correntropía matemáticamente como:

$$V(X, Y) = E[\kappa(X, Y)] = \int \kappa(x, y) dF_{XY}(x, y) \quad (2.9)$$

Donde E representa al operador de esperanza y $\kappa(\cdot, \cdot)$ corresponde a un kernel Mercer invariante a desplazamientos (teorema de Mercer, [4]). Para este filtro se emplea una función de kernel Gaussiana, dado por

$$\kappa(x, y) = G_\sigma(e) = \exp\left(-\frac{e^2}{2\sigma^2}\right) \quad (2.10)$$

Con este término definimos la *función de costo* de máxima correntropía.

$$J_{MCC} = \frac{1}{N} \sum_{i=1}^N G_\sigma(e(i)) \quad (2.11)$$

La ecuación 2.11 representa la función a maximizar. Su maximización calcula la estimación corregida para el estado en el instante k .

$$\hat{x}_k = \operatorname{argmax}_x (J_{MCC}) = \operatorname{argmax}_x \left(\sum_{i=1}^N G_\sigma(e_i(k)) \right) \quad (2.12)$$

Para obtener el máximo de correntropía se procede a calcular el error residual \tilde{e}_i (ecuación 2.13)

$$\tilde{e}_i = d_{i,k} - w_{i,k} \hat{x}_{t-1,k|k} \quad (2.13)$$

Con estos residuos definimos las matrices diagonales 2.14 y 2.15. La primera matriz corresponde a evaluaciones del kernel en errores estimados de predicción y la segunda en errores propios de las observaciones (ruido).

$$\tilde{C}_{x,k} = \operatorname{diag}(G_\sigma(\tilde{e}_{1,k}), \dots, G_\sigma(\tilde{e}_{n,k})) \quad (2.14)$$

$$\tilde{C}_{y,k} = \operatorname{diag}(G_\sigma(\tilde{e}_{n+1,k}), \dots, G_\sigma(\tilde{e}_{n+m,k})) \quad (2.15)$$

La siguiente expresión corresponde una transformación de la covarianza del ruido de las mediciones usando una descomposición de Choleski ($B_{r,k}$) en el instante k ([2]).

$$\tilde{R}_k = B_{r,k} \tilde{C}_{y,k}^{-1} B_{r,k}^T \quad (2.16)$$

Luego se calcula la transformación de la predicción de la matriz de covarianza de las estimaciones de estado, $P_{k|k-1}$ (ecuación 2.17).

$$\tilde{P}_{k|k-1} = B_{p,k|k-1} \tilde{C}_{x,k}^{-1} B_{p,k|k-1}^T \quad (2.17)$$

Posteriormente se calcula la ganancia de Kalman para este nuevo sistema.

$$\tilde{K} = \tilde{P}_{k|k-1} H_k^T (H_k \tilde{P}_{k|k-1} H_k^T + \tilde{R}_k)^{-1} \quad (2.18)$$

Finalmente la actualización de la estimación de estado para el instante k queda como:

$$\hat{x}_{t,k|k} = \hat{x}_{k|k-1} + \tilde{K}_k (y_k - H_k \hat{x}_{k|k-1}) \quad (2.19)$$

Las ecuaciones de la 2.13 a la 2.19 se repiten secuencialmente hasta satisfacer la condición:

$$\frac{\|\hat{x}_{t,k|k} - \hat{x}_{t-1,k|k}\|}{\|\hat{x}_{t-1,k|k}\|} \leq \epsilon \quad (2.20)$$

El valor de ϵ es definido por el usuario y corresponde a un criterio de detención (el algoritmo puede detenerse definiendo un máximo en el número de pasos).

$$P_{k|k} = \left(I - \tilde{K}_k H_k \right) P_{k|k-1} \left(I - \tilde{K}_k H_k \right)^T + \tilde{K}_k R_k \tilde{K}_k^T \quad (2.21)$$

Finalmente se calcula la matriz de covarianza para el instante actual, k (expresión 2.21).

2.4.3. Filtro de Kalman Unscented

1. Fase predictiva:

En esta versión del filtro ya no se habla de matrices de transición de estado, F_k , ni de matrices de transformación de estado-a-medición, H_k , sino más bien de funciones diferenciables f y h respectivamente para describir la transición de estados y la transformación de estos a estimaciones a priori. Sin embargo, previo a estas transiciones se deben seleccionar $2N+1$ puntos representativos alrededor de $\hat{x}_{k-1|k-1}$ y evaluar estos en la función no lineal f , para obtener las estimaciones de $x_{k|k-1}$ y $P_{k|k-1}$.




Figura 2.6: Representación del funcionamiento del filtro UKF. En esta oportunidad se hace uso de la función f y h para obtener las transformaciones $x_{k-1} \rightarrow x_k$ y $x_k \rightarrow z_k$. Esto se logra con la evaluación de de los $2N+1$ puntos generados durante la etapa de predicción (y posteriormente en la etapa de corrección).

La generación de los $2N+1$ puntos, se realiza a partir de la última estimación $\hat{x}_{k-1|k-1}$ de la siguiente forma

$$\begin{aligned} \bar{x}_{k-1|k-1}^0 &= \hat{x}_{k-1|k-1} \\ \bar{x}_{k-1|k-1}^0 &= \hat{x}_{k-1|k-1} + \chi_i, \quad \forall i \in [1, N] \\ \bar{x}_{k-1|k-1}^0 &= \hat{x}_{k-1|k-1} - \chi_{i-N}, \quad \forall i \in [N+1, 2N] \end{aligned} \quad (2.22)$$

Donde la cantidad χ_i corresponde a la i -ésima columna de la raíz cuadrada de la matriz:

$$(N + \lambda)P_{k-1|k-1} \quad (2.23)$$

Esta matriz (ec. 2.23) puede obtenerse a partir de la descomposición de Choleski. Por otro lado los puntos sigma se generan junto a dos conjuntos de pesos: $\{w_x^i\}$ y $\{w_p^i\}$. El primer conjunto se emplea en la estimación del estado y la predicción de la medida, mientras que el segundo conjunto es usado para obtener las matrices de covarianza relacionadas con el método. Estos pesos son definidos como:

$$\begin{aligned} w_x^0 &= \frac{\lambda}{N + \lambda} \\ w_p^0 &= w_x^0 + 1 - \alpha^2 + \beta \\ w_x^i &= w_p^i = \frac{1}{2(N + \lambda)} \\ \sum_i^{2N} w_x^i &= 1 \end{aligned} \quad (2.24)$$

De las ecuaciones 2.24 se desprende que los pesos w_x^i son normalizados. Por otro lado, el parámetro λ se puede escribir en términos de los valores de $\alpha \in (0, 1]$ y κ según la expresión 2.25

$$\lambda = \alpha^2(N + \kappa) - N \quad (2.25)$$

Los parámetros α , β y κ deben ser ajustados acorde al problema que se está estudiando.

Con esto, es posible escribir las ecuaciones de la fase predictiva.

- Estimación a priori de los estados

$$\hat{x}_{k|k-1} = \sum_{i=0}^{2N} w_x^i f(\bar{x}_{k-1|k-1}^i) \quad (2.26)$$

- Estimación a priori de la matriz de covarianza

$$P_{k|k-1} = \sum_{i=0}^{2N} w_p^i \left(f(\bar{x}_{k-1|k-1}^i) - \hat{x}_{k|k-1} \right) \left(f(\bar{x}_{k-1|k-1}^i) - \hat{x}_{k|k-1} \right)^T + Q_k \quad (2.27)$$

2. Fase correctiva:

Durante la fase de corrección, nuevamente se seleccionan $2N+1$ puntos representativos, alrededor de $\hat{x}_{k|k-1}$. Estos posteriormente son evaluados en la función no-linear h .

$$\begin{aligned} \bar{y}_{k-1|k-1}^0 &= \hat{x}_{k|k-1} \\ \bar{y}_{k-1|k-1}^i &= \hat{x}_{k|k-1} + \psi_i, \quad \forall i \in [1, N] \\ \bar{y}_{k-1|k-1}^i &= \hat{x}_{k|k-1} - \psi_{i-N}, \quad \forall i \in [N+1, 2N] \end{aligned} \quad (2.28)$$

La cantidad ψ_i representa el i -ésima columna de la matriz de *raíz cuadrada* $(N + \lambda)P_{k|k-1}$.

Las ecuaciones del proceso de corrección, por tanto, quedan como sigue:

- Predicción de las medidas:

$$\hat{z}_k = \sum_{i=0}^{2N} w_x^i h(y_{k|k-1}^{-i}) \quad (2.29)$$

- Los residuos de las mediciones pueden obtenerse como:

$$\tilde{z} = z_k - \hat{z}_k \quad (2.30)$$

- La matriz de innovación:

$$S_k = \sum_{i=0}^{2N} w_p^i (h(y_{k|k-1}^{-i}) - \hat{z}_k)(h(y_{k|k-1}^{-i}) - \hat{z}_k)^T + R_k \quad (2.31)$$

- La matriz de covarianza cruzada de estado a medida se describe:

$$C_k = \sum_{i=0}^{2N} w_p^i (f(\bar{x}_{k-1|k-1}^i) - \hat{x}_{k|k-1})(h(y_{k|k-1}^{-i}) - \hat{z}_k)^T \quad (2.32)$$

- La ganancia óptima finalmente queda:

$$K_k = C_k S_k^{-1} \quad (2.33)$$

- La estimación *a posteriori* de estado:

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \tilde{z} \quad (2.34)$$

- Por otro lado, la ecuación para la matriz de covarianza:

$$P_{k|k} = P_{k|k-1} - K_k S_k K_k^T \quad (2.35)$$

Los pesos w_x^i y w_p^i son los mismos calculados en la expresión 2.24, de la fase de predicción.

2.5. Ambiente de prueba: NLHPC

3 | Refactoring

3.1. Ejecución de la rutina

3.2. Manejo de datos de entrada

Toda la información de entrada es manipulada y procesada en la clase `DataPicker`. Esta clase se inicializa recibiendo un path hacia un archivo de configuración (el cual contiene las rutas a los archivos así como los nombres de sus archivos en términos de expresiones regulares `A.1`), semestre a los que corresponde la secuencia de observaciones (los dos últimos dígitos del año concatenados con la letra A en caso de corresponder al primer semestre o B al segundo), el campo (representado como un número de dos dígitos, comenzando con cero para valores menores a 10) y el CCD (cadena de tres caracteres donde el primero de ellos es una letra N para indicar que el chip se encuentra en el grupo de CCDs que apuntan hacia el norte del campo visual, o S para indicar que el chip corresponde al grupo de CCDs que apuntan hacia el lado sur; además de un par de dígitos identificadores que van de 01 a 36) como string.

- `maskDir`: Directorio donde se almacenan las imágenes máscara (imágenes que identifican píxeles).
- `scienceDir`: Directorio donde se almacenan las imágenes científicas
- `diffDir`: Directorio donde se almacenan las imágenes de diferencia
- `psfDir`: Directorio donde se encuentran los modelos de psf usados para la determinación del flujo.
- `invDir`: Directorio
- `afluxDir`:
- `maskRegex`: Expresión regular con la que es posible identificar el nombre de las imágenes máscara en disco siguiendo el path `maskDir`.

- **scienceRegex**: Expresión regular con la que es posible identificar el nombre de las imágenes científicas en disco siguiendo el path **scienceDir**.
- **diffRegex**: Expresión regular con la que es posible identificar el nombre de las imágenes de diferencia en disco siguiendo el path **diffDir**.
- **invRegex**: Expresión regular con la que es posible identificar el nombre de las imágenes máscara en disco siguiendo el path **invDir**.
- **afluxRegex**: Expresión regular con la que es posible identificar el nombre de las imágenes máscara en disco siguiendo el path **afluxDir**.
- **psfRegex**:
- **imgHeight**: Valor entero que indica alto de la imagen.
- **imgWidth**: Valor entero que indica ancho de la imagen.
- **only_HiTS_SN**:
- **results**: Directorio donde se irán almacenando los resultados tanto de las observaciones como de las predicciones realizadas con los filtros de Kalman de los potenciales candidatos a supernova.

DataPicker maneja dos tipos de procesos diferentes. Uno de ellos corresponde a la lectura y preparación de las imágenes a ser analizadas, mientras que el segundo proceso corresponde a la lectura de resultados anteriores (guardados en un archivo de texto plano) los cuales tienen el registro de las estimaciones y observaciones pasadas que se irán actualizando, con la finalidad de hacer el programa un proceso en línea.

3.2.1. Lectura y preparación de imágenes

A continuación se enumeran los diferentes métodos que intervienen en la recolección de los datos a ser leídos:

- **config_reg_expressions(semester, field, ccd)**

Este método recibe como parámetros el semestre (**semester**), el campo (**field**) y el ccd que la misma clase recibe de entrada. Con estos strings se establecen las rutas de los directorios de las imágenes y las expresiones regulares de los nombres de las mismas.

- `collect_data()`

Esta función se encarga de recolectar la ruta completa de las diferentes imágenes (máscaras, científicas, de diferencia, etc.). Para esta finalidad se hace uso del método `walking_through_files`.

- `walking_through_files(regex, dir)`

Método con el cual se recorren las rutas definidas en los pasos anteriores y se agrupan los nombres completos (directorio incluido) de las imágenes ubicadas en el directorio `dir` y posean un nombre de patrón que siga la expresión regular `regex`.

- `filter_science_images()`

Filtra imágenes científicas de acuerdo a su airmass

- `select_fits(dir)`

Ordena la lista de imágenes de formato fits del directorio `dir` en orden cronológico.

- `select_npy(dir, ref_dir, init_index, n_pos, rest_len):`

3.2.2. Resultados guardados

3.3. Determinación de flujos

El proceso de la obtención del flujo se simplificó, eliminando la clase `FitsHandler` del programa original. Debido a la posibilidad de hacer los métodos de esta clase estáticos se implementó un script Python denominada `utils` para contener estas rutinas e implementarlas estáticamente.

Los métodos que participan en la rutina de calculo de flujo son:

- `naylor_photometry(invvar, diff, psf):`

- `calc_fluxes(diff, psf, invvar, aflux):`

3.4. Filtros originales

A continuación se detallan las modificaciones realizadas en la implementación del filtro original.

3.4.1. Filtro básico

3.4.2. Filtro de máxima correntropía

3.5. Detección de candidatos

4 | Resultados

5 | Conclusiones

Capítulo Adicional que no es apéndice

Apéndices

A . Refactoring

A .1. Archivo de entrada: configuración de paths

```
maskDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s
scienceDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s
diffDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s
psfDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s/CALIBRATIONS
invDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s
afluxDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s/CALIBRATIONS
maskRegex = Blind%s_%s_%s_[0-9][0-9]_dqmask.fits.fz
scienceRegex = Blind%s_%s_%s_[0-9][0-9]_image_crblaster_grid02_lanczos2.fits
diffRegex = Diff_Blind%s_%s_%s_[0-9][0-9]t*-0[0-9]t*_grid02_lanczos2.fits
invRegex = invVAR_Blind%s_%s_%s_[0-9][0-9]t*-0[0-9]t*_grid02_lanczos2.fits
afluxRegex = match_Blind%s_%s_%s_[0-9][0-9]-0[0-9].npz
psfRegex = psf_Blind%s_%s_%s_[0-9][0-9]t*-0[0-9]t*_grid0[1-2]_lanczos2.npz
imgHeight = 2046
imgWidth = 4094
filter = ClassicKalman
only_HITS_SN = True
results = /home/paloma/Documents/Memoria/results/
```

A .2. Modelo de archivo de almacenamiento de resultados

B . Unit-tests

Referencias

- [1] B. Chen, X. Liu, H. Zhao, and J. C. Príncipe. Maximum Correntropy Kalman Filter. *ArXiv e-prints*, Sept. 2015.
- [2] B. Chen, X. Liu, H. Zhao, and J. C. Principe. Maximum correntropy kalman filter. *Automatica*, 76:70 – 77, 2017.
- [3] F. Forster, J. C. Maureira, S. Gonzalez-Gaitan, G. Medina, G. Pignata, L. Galbany, J. San Martin, M. Hamuy, P. Estevez, R. C. Smith, K. Vivas, S. Flores, P. Huijse, G. Cabrera, J. Anderson, F. Bufano, T. de Jaeger, J. Martinez, R. Munoz, E. Vera, and C. Perez. HiTS real-time supernova detections. *The Astronomer’s Telegram*, 7146, Feb. 2015.
- [4] B. J Mercer. Xvi. functions of positive and negative type, and their connection the theory of integral equations. *Phil. Trans. R. Soc. Lond. A*, 209(441-458):415–446, 1909.
- [5] R. E. Kalman. A New Approach to Linear Filtering and Prediction Problems. *Transactions of the ASME - Journal of Basic Engineering*, 82:35–45, 1960.
- [6] A. P. A. LSST Science Collaboration, A. J., and A. S. F. et al. *LSST Science Book, Version 2.0*. arXiv:0912.0201, 2009.