UNIVERSIDAD DE CHILE
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS
DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN

EXTENSIÓN DE FILTRO DE KALMAN DE APROXIMACIÓN NO LINEAL PARA LA DETECCIÓN DE OBJETOS ASTRONÓMICOS

MEMORIA PARA OPTAR AL TÍTULO DE INGENIERA CIVIL EN COMPUTACIÓN

PALOMA PÉREZ GARCÍA

PROFESOR GUÍA:
SR. PABLO ESTEVEZ VALENCIA

MIEMBROS DE LA COMISIÓN:
SR. BENJAMÍN BUSTOS
SR. AIDAN HOGAN

SANTIAGO DE CHILE
DICIEMBRE 2018

Resumen Ejecutivo

...

Agradecimientos

Paloma Pérez García

Índice general

Índice de cuadros

Índice de figuras

1 | Introducción

1.1. Motivación

La astronomía es uno de los campos científicos que más se ha visto afectado por el rápido crecimiento en la generación de datos debido al fuerte desarrollo de nuevas tecnologías de la información y de nuevos instrumentos destinados a la observación. Este crecimiento ha gatillado un aumento importante en la demanda de una nueva generación de métodos que puedan procesar esta oleada de información o big data astronómico.

Ejemplos de proyectos que actualmente producen una gran cantidad de datos a través de telescopios en diferentes partes del mundo son: el Panoramic Survey Telescope and Rapid Response System (Pan-STARRS), el Visible and Infrarred Survey Telescope (VISTA), el VLT Survey Telescope (VST), el Dark Energy Camera Legacy Survey (DECaLS) y el Hyper Suprime-Cam Subaru Strategic Program (HSC SSP). Estos surveys están caracterizados por un amplio *étendue* que consiste en el producto entre el área del espejo de un telescopio y su ángulo sólido proyectado en el cielo.

En el futuro, telescopios como el Large Synoptic Survey Telescope (LSST) [6] (que entrará en funcionamiento a mediados del 2022) continuarán revolucionando la era del big data en astronomía con etendues y cámaras CCD mucho más grandes de lo que hasta el día de hoy se utiliza. En particular se espera que el LSST produzca un número de alertas transientes (avisos de objetos encontrados y su consecuente seguimiento) del orden del millón cada noche. La capacidad de detectar nuevos objetos de interés dependerá de la calidad de los datos y de los algoritmos de tiempo real destinados a generar las alertas mencionadas.

Al día de hoy se han elaborado sondeos como el High Cadence Transient Survey (HiTS) [3] cuya finalidad ha sido la búsqueda de fenómenos transientes rápidos con escalas de tiempo que van desde las horas a días, utilizando secuencias de observaciones de la cámara DECam del telescopio Blanco (en Cerro Tololo) para la detección y posterior reporte de objetos candidatos a supernova.

En este trabajo proponen un método de detección de potenciales candidatos a supernova a través de la discriminación de píxeles que involucren un incremento trasiente de intensidad.

Esta discriminación comienza con la determinación del flujo a través de la intensidad de los píxeles que puedan corresponder a una estrella y a la variación de cada uno de ellos usando métodos iterativos de filtrado en secuencias de imágenes de largo arbitrario. Los filtros pensados para HiTS corresponden a miembros de una familia de filtros conocidos como *filtros de Kalman*. En particular se hace uso de los filtros de Kalman básico [5] y de correntropía máxima [2].

El reciente trabajo desarrollado por Pablo Huentelemu [8] (M.Sc.) guiado por Pablo Estévez (PhD) y Francisco Förster (PhD), propone el uso de estos filtros en el reconocimiento de supernovas jóvenes (o en su fase de crecimiento de luminosidad) de tipo II, por lo que se plantea la posibilidad de diseñar algún otro criterio de filtrado y de estudiar la variación de los resultados.

1.2. Objetivos

El objetivo de esta tesis comprende la reestructuración de un programa destinado al análisis fotométrico de datos astronómicos con él cual se busca implementar una base de sistema de alertas que de aviso del estado temprano de una posible supernova de tipo II. Es decir, que notifique el momento en que la luminosidad de una estrella comience a crecer debido a este tipo de explosión.

El llevar a cabo este refactorización requiere la familiarización con una familia de métodos conocido como Filtros de Kalman que hacen uso de las mediciones obtenidas sobre un sistema dinámico empleando la incertidumbre de las observaciones y del sistema en la estimación del estado de este. Esto, con la finalidad de poder desarrollar una familia de métodos en términos de programación orientada a objetos empleando el patrón de diseño Strategy.

La refactorización de los métodos de filtrado existentes (básico y de máxima correntropía [8]) va acompañada del desarrollo de una nueva variante que permita el uso de un modelo no lineal y control sobre él mismo (es decir, que el usuario pueda decidir qué modelo no-lineal emplear para sus estimaciones).

Por otro lado, se requiere un breve proceso de ingeniería sobre la manipulación de los archivos requisito del programa original, debido a que existen problemas de *hard-coding* respecto de la ubicación de estos, así como ciertos reparos durante el proceso de selección de los mismos. Además se

necesita reformular la configuración de parámetros funcionales de entrada (propios de la ejecución del programa, como los umbrales) para flexibilizar la configuración de estos últimos.

Por otra parte, se desea implementar una nueva alternativa en la obtención de las gráficas de resultados en las que sea posible observar la medición y error de la entropía al obtener las curvas de estado (espacio de fase) de flujo y velocidad de flujo.

Finalmente se busca estudiar los resultados obtenidos con esta nueva versión del programa con cada uno de sus filtros sobre un conjunto de datos brindado por HiTS (del año 2015), a la par que el desempeño de este. Por último se busca establecer un contraste con la versión original.

1.3. Organización de la tesis

Este documento sigue los siguientes capítulos: en el Capítulo 2 se describe en qué consiste una supernova, el proyecto HiTS así como el background matemático de los métodos de filtrado usados en el trabajo original (filtros de Kalman básico y de máxima correntropía) y el filtro a implementar (filtro de Kalman unscented).

En el Capítulo 3, se estudian tanto el desempeño como los resultados obtenidos con el código original del programa sobre el cual se trabajará, estableciéndose una breve discusión sobre estos resultados.

Posteriormente, en el Capítulo 4 se describe el refactoring del programa del código original: se enlistan nuevos métodos para el manejo de archivos y cambios realizados en la implementación de los métodos iniciales.

En el Capítulo 5 se exponen los pasos del desarrollo del nuevo filtro además de la nueva funcionalidad relacionada con la carga de resultados previamente guardados en pos de hacer este programa un proceso on-line.

Posteriormente, en el capítulo 6, se exponen los resultados obtenidos para el desempeño de la nueva versión del programa (para los dos filtros originales) además de la cantidad de supernovas redescubiertas y el periodo en que se detectaron. El capítulo concluye con el análisis de los estos resultados y una comparación con aquellos obtenidos en el Capítulo 3.

Finalmente las conclusiones, contenidas en el capítulo 7, resumen el aprendizaje obtenido durante este trabajo así como los resultados relevantes logrados durante las pruebas realizadas. Además se plantean nuevas líneas de trabajo futuro.

2 | Antecedentes

En el presente Capítulo se exponen conceptos cruciales para la comprensión y desarrollo de este trabajo. Se describe en particular los objetos de interés que estimularon el desarrollo del Survey HiTS y al mismo proyecto: las supernovas de tipo II y el evento de short-breakout asociado a estas. De la misma forma, se describe la base matemática en la que se basan las diferentes versiones del filtro de Kalman implementadas en el software original, es decir, los filtros de Kalman *básico* y de *máxima correntropía* así como una nueva versión del método conocida como *unscented* que permitiría la introducción de modelos no lineales en el proceso de filtrado.

2.1. Supernova tipo II

Una supernova de tipo II corresponde a un evento estelar con el que finaliza la vida de una estrella masiva (aquellas que en su proceso de formación poseen una masa superior a 10 masas solares [1]). Al ya no contar con combustible necesario para llevar a cabo reacciones nucleares que puedan contrarrestar su propia gravedad (su núcleo ya no puede formar elementos más pesados que el hierro o el níquel), y si la presión degenerada de los electrones del plasma de la estrella no es suficiente para soportar este peso, la estrella se contrae abruptamente incrementando la temperatura de su centro a 10^{10} K.

Debido al aumento de temperatura, los electrones del núcleo adquieren energía cinética suficiente para escapar, desapareciendo así la presión que ejercían hacia el exterior. Finalmente el núcleo colapsa liberando energía gravitacional y con ella las más externas de la estrella son expulsadas en una gran explosión. Este fenómeno se denomina *supernova* e implica un aumento repentino del brillo de una estrella, incrementando su brillo en un factor de 10^8 veces, pudiendo incluso ser más brillante que la galaxia que la alberga.

En general la variación de la luminosidad de una supernova corresponde a una curva que crece rápidamente los primeros días (u horas), alcanzando un máximo, para luego decaer. Cabe destacar

[1] $M_\odot = (1.98847 \pm 0.00007) \times 10^{30}$ Kg

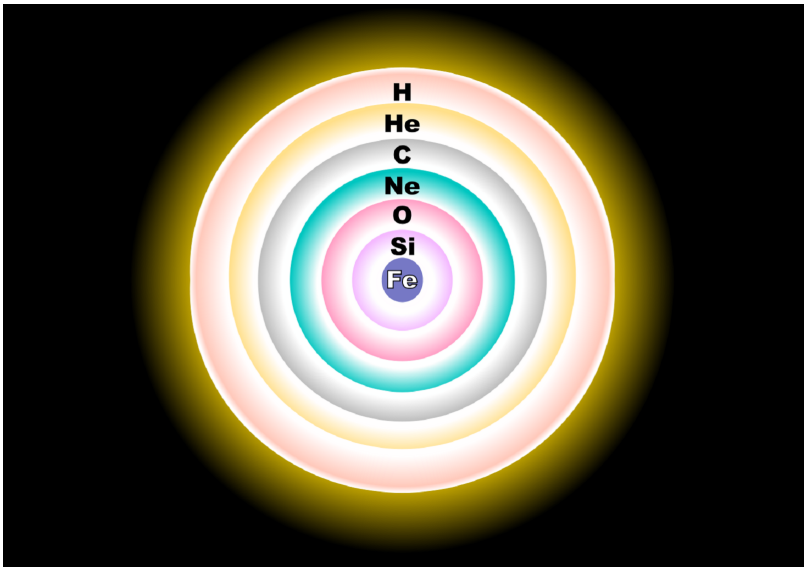

Figura 2.1: Esquema no a escala de la estructura de una estrella masiva previo a su explosión como supernova. Los elementos más pesados se alojan en el centro, mientras que los más livianos, como el hidrógeno o el helio lo hacen en la capa más externa. *Imagen publicada por R. J. Hall en WikiMedia Commons, 15 de agosto de 2007.*

que existe otro tipo de supernova, las de tipo I y corresponden a otro fenómeno en donde participa una clase de estrella denominada enana blanca junto a otra estrella de cualquier otro tipo. La primera, al poseer una gravedad tan alta en su superficie es capaz de tomar material de su compañera con lo que al superar las 1.44 $M_\odot$ se desencadenaría la explosión de supernova I.

Las supernovas de tipo I presentan un decaimiento casi continuo una vez alcanzado el máximo, mientras que las de tipo II presentan dos caídas: una inmediatamente después de su máximo y otra una vez finalizado un periodo de decaimiento suavizado (figura 2.2). Otra forma de diferenciarlas es la presencia de trazas de hidrógeno en los espectros de estas: las supernovas de tipo I practicamente no presentan hidrógeno (líneas de absorción distintivas) a diferencia de las de tipo II.

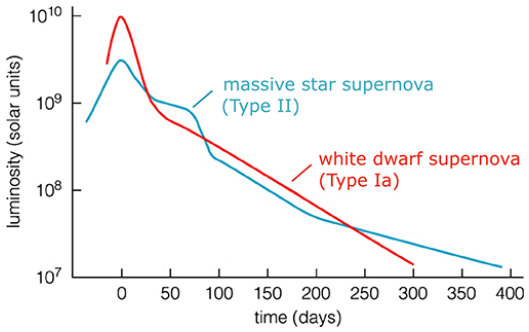

Figura 2.2: Curvas típicas de supernovas I (enana blanca) y II (estrella masiva). ©*2004 Pearson Education Inc., publishing as Addison-Wesley The Bizarre Stellar Graveyard.*

2.2. High Cadence Transient Survey: HiTS

El High Cadence Transient Survey [3] (desde ahora, HiTS) es un survey cuyo objetivo principal es el detectar y seguir fenómenos transientes estelares en escalas de tiempo que van desde horas a días, con especial atención a fases tempranas de explosiones de supernovas (primeras horas): el objetivo original de HiTS corresponde a la detección de un fenómeno llamado *shock breakout* (SBO), un fenómeno que ocurre inmediatamente después del colapso del núcleo de una estrella roja supergigante (una de las posibles etapas finales de una estrella masiva antes de *explotar* en supernova II). Ver figura 2.3[2].

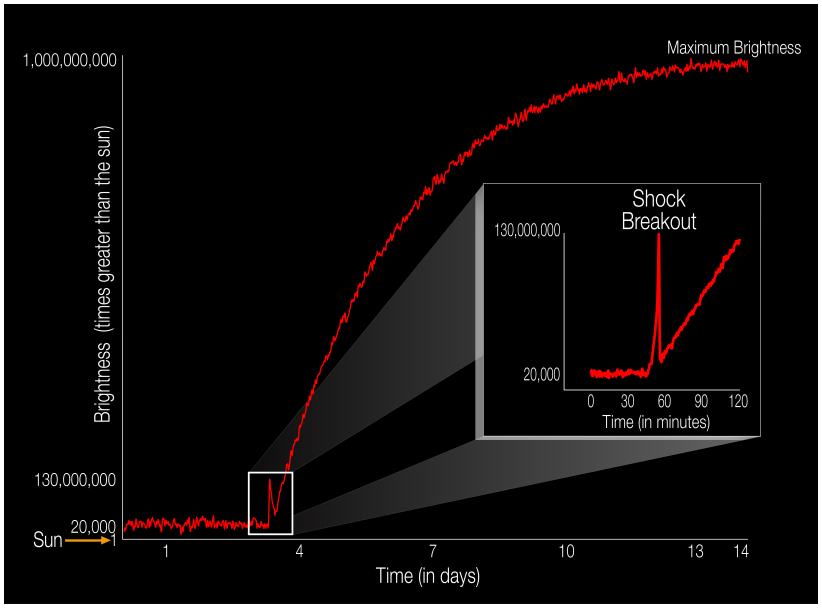

Figura 2.3: Diagrama que ilustra la evolución del brillo de una supernova en términos de luminosidad solar ($L_\odot$) durante días. Se resalta el fenómeno de shock breakout apenas comienza el incremento de la luminosidad de la supernova. Esta imagen fue publicada en la página de la NASA destacando la primera vez que un evento como este es *capturado* en la banda visible (por el telescopio espacial Kepler).*NASA Ames/W. Stenzel. 2016*

HiTS utiliza la Dark Energy Camera (DECam, figura 2.4) para la obtención de sus imágenes. Esta cámara se encuentra montada en el Telescopio Blanco del Observatorio de Cerro Tololo (CTIO) en la región de Coquimbo, Chile. Esta cámara posee 62 detectores CCD de 2048×4096 píxeles para la obtención de imágenes científicas y otros 12 para la guía, alineamiento y enfoque.

Durante este proyecto se han realizado tres campañas de observación en los años 2013, 2014 y 2015 durante el primer semestre de cada año. Se escogieron 40 campos y 4 épocas por noche (también por campo) para observaciones para el año 2013 y en el 2014. Para la campaña del año 2015 se

[2] $L_\odot = 3.828 \times 10^{26}$ W

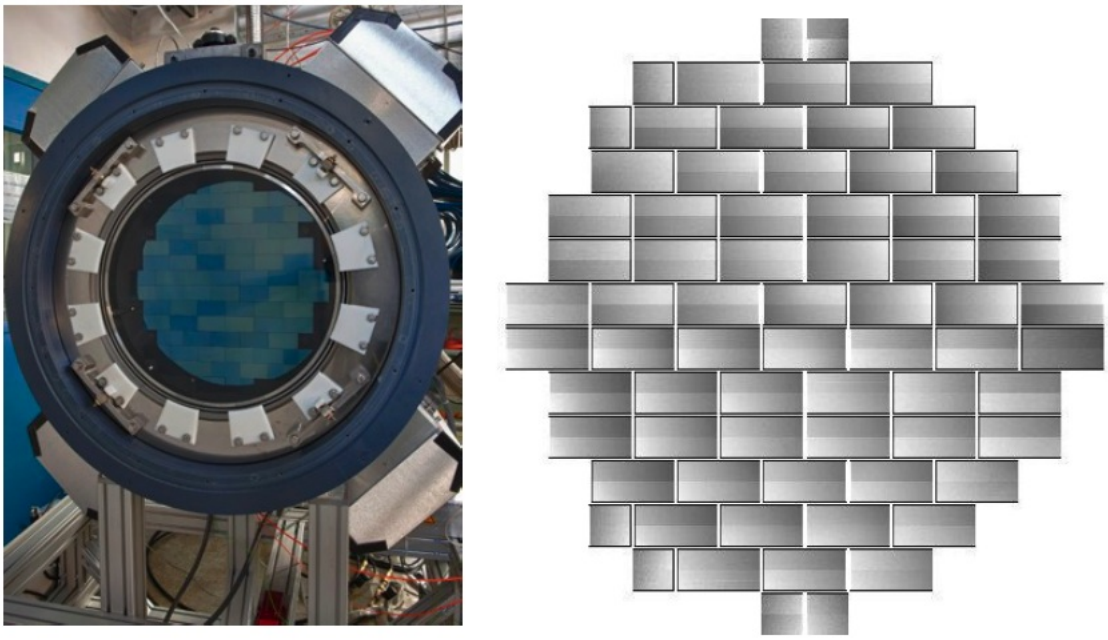

Figura 2.4: A la izquierda, estructura de la cámara DECam poblada con 62 chips CCDs. A la derecha, imagen *flat field* desde DECam. *Imágenes tomadas desde la página del Dark Energy Survey (www. darkenergysurvey. org/ the-des-project/ instrument/ the-camera).*

escogieron 50 campos. Dentro de estas campañas obtuvieron más de 120 candidatos a supernova. Sin embargo, no se logró encontrar en estas rastros de SBO (figura 2.3) evento que comprendió uno de los principales objetivos de HiTS.

2.3. El filtro de Kalman

La evolución determinística de un sistema físico en el tiempo es conocido si el estado del sistema es medido con absoluta precisión en cada instante de tiempo (i.e., en un entorno donde es posible despreciar fenómenos cuánticos). Sin embargo toda medición está sujeta a incertezas finitas. Para sistemas los cuales son observados entre intérvalos prolongados de tiempo, se prevee que las diferencias entre los estados estimados y los medidos se incrementen con el tiempo. Para la obtención de predicciones lo más confiables posible se requiere que el sistema sea regularmente monitoreado y sus estados estimados puedan ser considerados confiables en un lapso de tiempo en apropiado.

Los filtros de Kalman son métodos que proveen un trade-off entre los valores esperados del estado actual de un sistema y las mediciones que proporcionan información de su estado real. La aplicación de un filtro de Kalman está pensada como un proceso de dos fases:

1. **Fase predictiva:** Una estimación del estado actual del sistema que se basa en la estimación del estado previo o último estado. Esta predicción se denomina usualmente como estado estimado

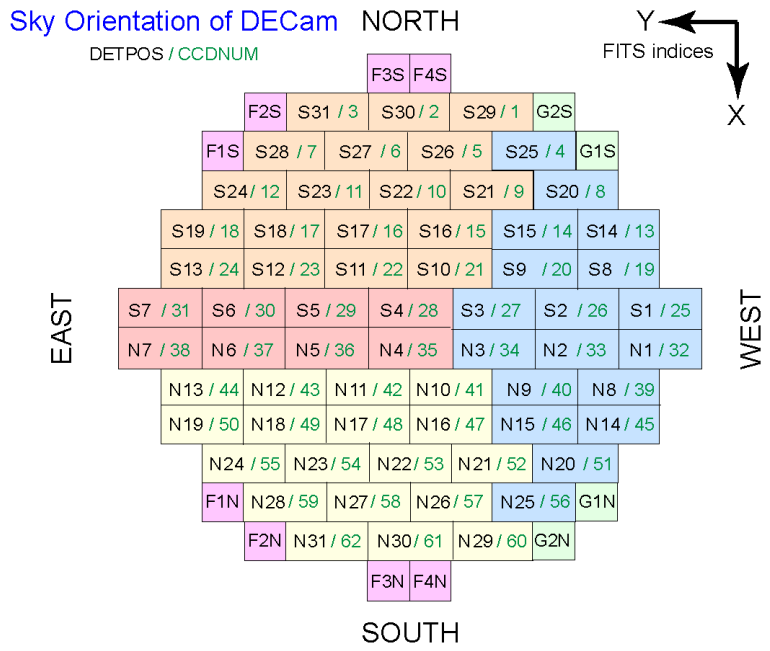

Figura 2.5: Orientaciones sobre el cielo y la huella espacial del arreglo de detectores en el plano focal. Se destacan los CCD cuya etiqueta comienzan con S o N, ya que estos corresponden a los detectores encargados de obtener las imágenes científicas. El etiquetado de estas componentes puede ser engañoso debido a que las iniciales de norte (North) y sur (South) están invertidas en relación a la orientación del cielo. *Imagen publicada en el sitio del CTIO (http://www.ctio.noao.edu/noao/node/2250).*

a priori.

2. **Fase correctiva:** La estimación del estado *a priori* es corregida con una medida actual para refinar la aproximación. Esta mejora se denomina *aproximación a posteriori*.

Típicamente estas fases de predicción y corrección se van alternando mientras se estudie el comportamiento físico de algún sistema.

2.3.1. Filtro de Kalman Básico

El filtro de Kalman Básico asume un comportamiento de sistema lineal y que las mediciones y las predicciones siguen una distribución Gaussiana.

A continuación se describen las componentes del desarrollo matemático del filtro:

- F_k**:** Matriz de transición de estado, de dimensiones $N \times N$ (N es el número de variables de estado).

- H_k**:** Matriz de transformación de estado a medición, $K \times N$ (K corresponde a las mediciones realizadas en un instante k de una variable de estado).

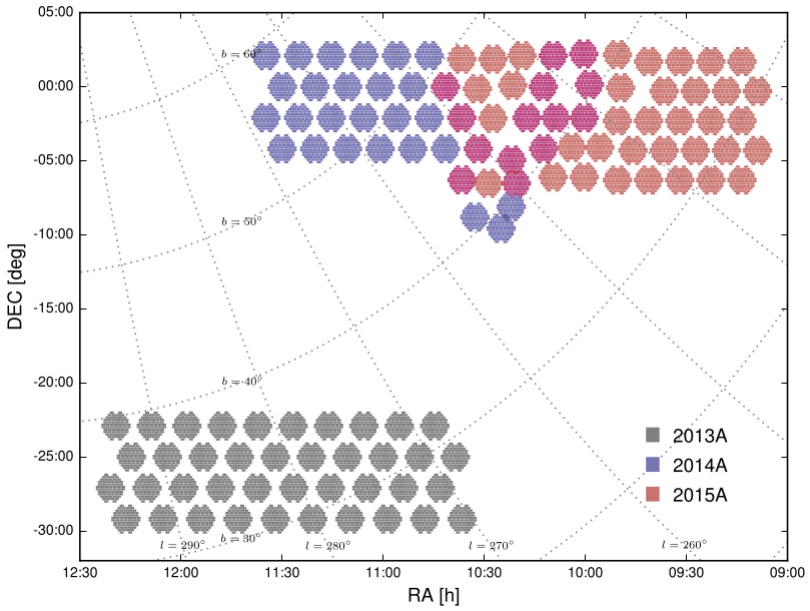

Figura 2.6: Distribución espacial de los campos observados durante los primeros semestres de los años 2013 (gris), 2014 (azul) y 2015 (naranjo). En tono rojo, los mismos campos del año 2015 y 2014 (superposición). *F. Förster et al., 2015. HiTS real-time supernova detections.*

- Q_k**:** Matriz de covarianza del ruido del proceso ($N \times N$).
- R_k**:** Matriz de covarianza del ruido de las mediciones ($K \times K$).
- B_k**:** Matriz de control de entrada (contiene alteraciones que se querrían agregar al sistema de manera deliberada, por ejemplo, como la condición de parada de un vehículo en movimiento). Esta matriz es de dimensiones $N \times L$, donde L es la dimensión del vector de control de entrada u_k.

Se hará uso de la notación en subíndices $m|n$, en las estimaciones de estado y covarianzas, para explicitar el instante de tiempo al cual pertenecen: m; y al instante de tiempo de donde se extrae la información: n.

En el instante $k-1$, se obtienen dos cantidades

- $\hat{x}_{k|k-1}$: Estado estimado *a priori*.
- $P_{k|k-1}$: Matriz de covarianza *a priori*.

Luego, en la fase de corrección se calculan:

- $\hat{x}_{k|k}$: Estado estimado *a posteriori*.

- $P_{k|k}$: Matriz de covarianza *a posteriori*.

Con estas variables, podemos describir las Ecuaciones que explican la evolución del proceso de este algoritmo:

1. **Fase predictiva:**

   Estimación de estado y matriz de covarianza *a priori*.

$$\hat{x}_{k|k-1} = F_k \hat{x}_{k-1|k-1} + B_k u_k \tag{2.1}$$

$$P_{k|k-1} = F_k P_{k-1|k-1} F_k^T + Q_k \tag{2.2}$$

2. **Fase correctiva:**

   Estimación de estado y matriz de covarianza *a posteriori*.

$$\hat{z}_k = H_k \hat{x}_{k|k-1} \tag{2.3}$$

$$\tilde{z}_k = z_k - \hat{z}_k \tag{2.4}$$

   La Ecuación 2.4 describe la obtención de un residuo de la diferencia entre la predicción y la medida z_k. Posteriormente se calcula la matriz de covarianza entre residuos (2.5), con la que se calcula la ganancia de Kalman (ecuación 2.6).

$$S_k = H_k P_{k|k-1} H_k^T + R_k \tag{2.5}$$

$$K_k = P_{k|k-1} H_k^T S_k^{-1} \tag{2.6}$$

   Con la ganancia de Kalman calculada, se actualiza el valor de la estimación de estado (2.7) y matriz de covarianza a posteriori (2.8).

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \tilde{z}_k \tag{2.7}$$

$$P_{k|k} = (I_N - K_k H_k) P_{k|k-1} \tag{2.8}$$

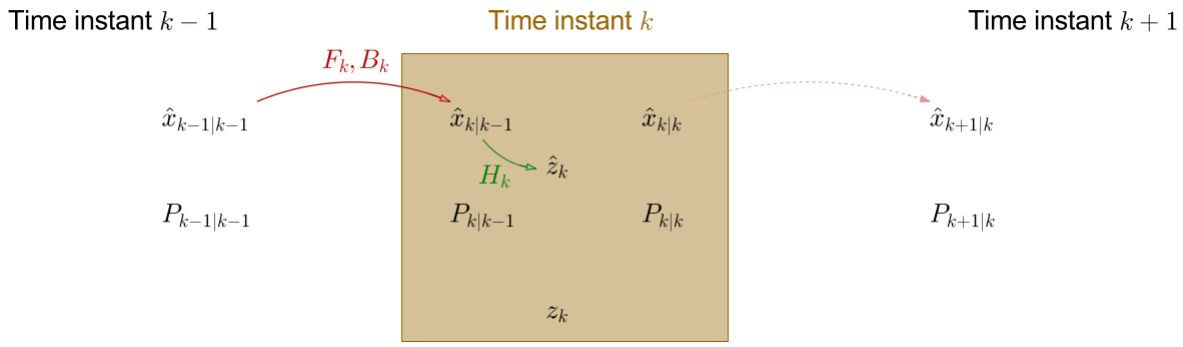

Figura 2.7: Representación del proceso de predicción (obtención de cantidades a priori) de las cantidades $\hat{x}_{k|k-1}$ y $P_{k|k-1}$; y de corrección (estimación a posteriori) para obtener las cantidades $\hat{x}_{k+1|k}$ y $P_{k+1|k}$. *E. Matsinos, 2016. The Kalman Filter: a didactical overview.*

2.3.2. Filtro de Kalman de Máxima Correntropía

El filtro de Kalman basado en correntropía máxima [1], difiere del filtro de Kalman tradicional (básico) en que no asume gaussianidad en las observaciones, considerando casos en que una señal puede ser perturbada por pulsos de ruido que sigan una distribución de cola pesada. En esta oportunidad se utiliza el *criterio de correntropía máxima* para el proceso de correción.

Recordando que la correntropía es una medida de similitud entre dos variables aleatorias, supongamos, $X, Y \in \mathbb{R}$ con una distribución conjunta $F_{XY}(x, y)$, definimos la correntropía matemáticamente como:

$$V(X,Y) = E[\kappa(X,Y)] = \int \kappa(x,y) dF_{XY}(x,y) \tag{2.9}$$

donde E representa al operador de esperanza y $\kappa(,)$ corresponde a un kernel Mercer invariante a desplazamientos (teorema de Mercer, [4]). Para este filtro se emplea una función de kernel Gaussiana, dado por

$$\kappa(x,y) = G_\sigma(e) = exp\left(-\frac{e^2}{2\sigma^2}\right) \tag{2.10}$$

Con este término definimos la *función de costo* de máxima correntropía.

$$J_{MCC} = \frac{1}{N}\sum_{i=1}^{N} G_\sigma(e(i)) \tag{2.11}$$

La Ecuación 2.11 representa la función a máximizar. Su maximización calcula la estimación corregida para el estado en el instante k.

$$\hat{x}_k = argmax_x(J_{MCC}) = argmax_x(\sum_{i=1} G_\sigma(e_i(k))) \tag{2.12}$$

Para obtener el máximo de correntropía se procede a calcular el error residual $\tilde{e}_i$ (Ecuación 2.13)

$$\tilde{e}_i = d_{i,k} - w_{i,k}\hat{x}_{t-1,k|k} \tag{2.13}$$

Con estos residuos definimos las matrices diagonales, descritas en las Ecuaciones, 2.14 y 2.15. La primera matriz corresponde a evaluaciones del kernel en errores estimados de predicción y la segunda en errores propios de las observaciones (ruido).

$$\tilde{C_{x,k}} = diag(G_\sigma(\tilde{e}_{1,k}), ..., G_\sigma(\tilde{e}_{n,k})) \tag{2.14}$$

$$\tilde{C_{y,k}} = diag(G_\sigma(\tilde{e}_{n+1,k}), ..., G_\sigma(\tilde{e}_{n+m,k})) \tag{2.15}$$

La siguiente expresión corresponde una transformación de la covarianza del ruido de las mediciones usando una descomposición de Choleski ($B_{r,k}$) en el instante k ([2]).

$$\tilde{R}_k = B_{r,k}\tilde{C}_{y,k}^{-1}B_{r,k|k-1}^T \tag{2.16}$$

Luego se calcula la transformación de la predicción de la matriz de covarianza de las estimaciones de estado, $P_{k|k-1}$ (Ecuación 2.17).

$$\tilde{P}_{k|k-1} = B_{p,k|k-1}\tilde{C}_{x,k}^{-1}B_{p,k|k-1}^T \tag{2.17}$$

Posteriormente se calcula la ganancia de Kalman para este nuevo sistema.

$$\tilde{K} = \tilde{P}_{k|k-1}H_k^T(H_k\tilde{P}_{k|k-1}H_k^T + \tilde{R}_k)^{-1} \tag{2.18}$$

Finalmente la actualización de la estimación de estado para el instante k queda como:

$$\hat{x}_{t,k|k} = \hat{x}_{k|k-1} + \tilde{K}_k(y_k - H_k\hat{x}_{k|k-1}) \tag{2.19}$$

Las Ecuaciones de 2.13 a 2.19 se repiten secuencialmente hasta satisfacer la condición:

$$\frac{\| \hat{x}_{t,k|k} - \hat{x}_{t-1,k|k} \|}{\| \hat{x}_{t-1,k|k} \|} \leq \epsilon \tag{2.20}$$

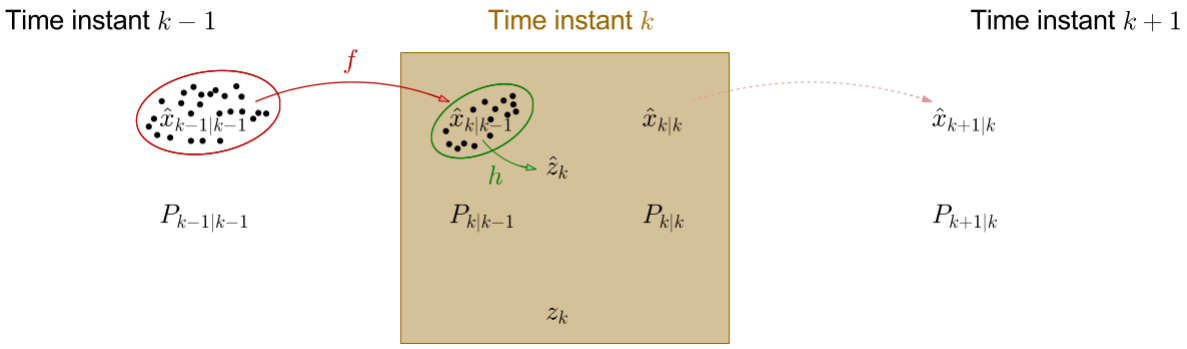

Figura 2.8: Representación del funcionamiento del filtro UKF. En esta oportunidad se hace uso de la función f y h para obtener las transformaciones $x_{k-1} \rightarrow x_k$ y $x_k \rightarrow z_k$. Esto se logra con la evaluación de de los 2N+1 *puntos sigma* generados durante la etapa de predicción (y posteriormente en la etapa de corrección). *E. Matsinos, 2016. The Kalman Filter: a didactical overview.*

El valor de ϵ es definido por el usuario y corresponde a un criterio de detención (el algoritmo puede detenerse definiendo un máximo en el número de pasos).

$$P_{k|k} = \left(I - \tilde{K}_k H_k\right) P_{k|k-1} \left(I - \tilde{K}_k H_k\right)^T + \tilde{K}_k R_k \tilde{K}_k^T \tag{2.21}$$

Finalmente se calcula la matriz de covarianza para el instante actual, k (Ecuación 2.21).

2.3.3. Filtro de Kalman Unscented

Este filtro corresponde a aquel que se pretende agregar a la familia de filtros ya desarrollada en el programa base.

1. **Fase predictiva:**

   En esta versión del filtro [9] ya no se habla de matrices de transición de estado, F_k, ni de matrices de transformación de estado-a-medición, H_k, sino más bien de funciones diferenciables f y h respectivamente para describir la transición de estados y la transformación de estos a estimaciones a priori. Sin embargo, previo a estas transiciones se deben seleccionar 2N+1 puntos representativos alrededor de $\hat{x}_{k-1|k-1}$ y evaluar estos en la función no lineal f, para obtener las estimaciones de $x_{k|\hat{k-1}}$ y $P_{k|k-1}$. Estos puntos se conocen como *puntos sigma.*

   La generación de los 2N+1 puntos, se realiza a partir de la última estimación $\hat{x}_{k-1|k-1}$ de la siguiente forma

$$\begin{aligned} \bar{x}^0_{k-1|k-1} &= \hat{x}_{k-1|k-1} \\ \bar{x}^0_{k-1|k-1} &= \hat{x}_{k-1|k-1} + \chi_i, \quad \forall i \in [1, N] \\ \bar{x}^0_{k-1|k-1} &= \hat{x}_{k-1|k-1} - \chi_{i-N}, \quad \forall i \in [N+1, 2N] \end{aligned} \tag{2.22}$$

donde la cantidad χ_i corresponde a la i-ésima columna de la *raíz cuadrada* de la matriz:

$$(N + \lambda)P_{k-1|k-1} \tag{2.23}$$

Esta matriz (Ecuación 2.23) puede obtenerse a partir de la descomposicón de Choleski. Por otro lado los puntos sigma se generan junto a dos conjuntos de pesos: $\{w_x^i\}$ y $\{w_p^i\}$. El primer conjunto se emplea en la estimación del estado y la predicción de la medida, mientras que el segundo conjunto es usado para obtener las matrices de covarianza relacionadas con el método. Estos pesos son definidos como:

$$\begin{aligned} w_x^0 &= \frac{\lambda}{N+\lambda} \\ w_p^0 &= w_x^0 + 1 - \alpha^2 + \beta \\ w_x^i &= w_p^i = \frac{1}{2(N+\lambda)} \\ \sum_i^{2N} w_x^i &= 1 \end{aligned} \tag{2.24}$$

De las Ecuaciones 2.24 se desprende que los pesos w_x^i son normalizados. Por otro lado, el parámetro λ se puede escribir en términos de los valores de $\alpha \in (0, 1]$ y κ según la expresión 2.25

$$\lambda = \alpha^2(N + \kappa) - N \tag{2.25}$$

Los parámetros α, β y κ deben ser ajustados acorde al problema que se está estudiando.

Con esto, es posible escribir las Ecuaciones de la fase predictiva.

- Estimación a priori de los estados

$$\hat{x}_{k|k-1} = \sum_{i=0}^{2N} w_x^i f(\bar{x}_{k-1|k-1}^i) \tag{2.26}$$

- Estimación a priori de la matriz de covarianza

$$P_{k|k-1} = \sum_{i=0}^{2N} w_p^i \left(f(\bar{x}_{k-1|k-1}^i) - \hat{x}_{k|k-1}\right)\left(f(\bar{x}_{k-1|k-1}^i) - \hat{x}_{k|k-1}\right)^T + Q_k \tag{2.27}$$

2. **Fase correctiva:**

Durante la fase de corrección, nuevamente se seleccionan 2N+1 puntos representativos, alrededor de $\hat{x}_{k|k-1}$. Estos posteriormente son evaluados en la función no-linear h.

$$\begin{aligned} \bar{y}^0_{k-1|k-1} &= \hat{x}_{k|k-1} \\ \bar{y}^i_{k-1|k-1} &= \hat{x}_{k|k-1} + \psi_i, \quad \forall i \in [1, N] \\ \bar{y}^i_{k-1|k-1} &= \hat{x}_{k|k-1} - \psi_{i-N}, \quad \forall i \in [N+1, 2N] \end{aligned} \tag{2.28}$$

La cantidad ψ_i representa el i-ésima columna de la matriz de *raíz cuadrada* $(N+\lambda)P_{k|k-1}$.

Las Ecuaciones del proceso de corrección, por tanto, quedan como sigue:

- Predicción de las medidas:

$$\hat{z}_k = \sum_{i=0}^{2N} w^i_x h(y^{-i}_{k|k-1}) \tag{2.29}$$

- Los residuos de las mediciones pueden obtenerse como:

$$\tilde{z} = z_k - \hat{z}_k \tag{2.30}$$

- La matriz de innovación:

$$S_k = \sum_{i=0}^{2N} w^i_p (h(y^{-i}_{k|k-1}) - \hat{z}_k)(h(y^{-i}_{k|k-1})^T + R_k \tag{2.31}$$

- La matriz de covarianza cruzada de estado a medida se describe como:

$$C_k = \sum_{i=0}^{2N} w^i_p (f(\bar{x}^i_{k-1|k-1}) - \hat{x}_{k|k-1})(h(y^{-i}_{k|k-1}) - \hat{z}_k)^T \tag{2.32}$$

- La ganancia óptima finalmente queda:

$$K_k = C_k S_k^{-1} \tag{2.33}$$

- La estimación *a posteriori* de estado:

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \tilde{z} \tag{2.34}$$

- Por otro lado, la ecuación para la matriz de covarianza:

$$P_{k|k} = P_{k|k-1} - K_k S_k K_k^T \tag{2.35}$$

Los pesos w^i_x y w^i_p son los mismos calculados en la expresión 2.24, de la fase de predicción.

2.4. Laboratorio Nacional de Computación de Alto Desempeño (NLHPC)

El National Laboratory for High Performance Computing (NLHPC) es un proyecto asociativo, financiado por el PIA de CONICYT el cual dispone de un potente sistema computacional el cual está disponible a la comunidad científica y académica nacional (instituciones de investigación, industria y universidades), estimulando su uso en el desarrollo de áreas de investigación que requieran de herramientas computacionales robustas que deban ser usadas de manera intensiva.

Para la realización de esta tesis se hará uso de uno de los nodos del clúster de Leftraru, el supercomputador del NLHPC disponible para la comunidad investigadora desde el 2014 en las instalaciones del Centro de Modelamiento Matemático (CMM) de la Universidad de Chile.

- 132 nodos de cómputo HP (128 nodos HP SL230 y 4 nodos HP SL250), cada uno con dos procesadores de 10 cores Intel Xeon Ivy Bridge E5-2660 V2.
- 2640 núcleos
- 6.25 TB de RAM
- 274TB de almacenamiento Lustre (DDN EXAScaler)
- 12 co-procesadores Intel Xeon Phi5110p de 2 TFlops
- Capacidad de cómputo de 70 TFlops

Para la ejecución de las pruebas se emplearán cuatro cores, 2400 MB por cada CPU (máxima RAM permitida) y un *job-array* de largo 93.

3 | Desempeño del programa original

A continuación se exponen los resultados de diferentes pruebas realizadas sobre el programa original con la finalidad de medir su desempeño computacional en términos de tiempo de ejecución y uso de memoria.

Estas pruebas se llevaron a cabo en un computador personal de 8 GB (DDR4) de RAM. La razón de esta medida (que no se hayan ejecutado en Leftraru) tuvo que ver con que el código original contiene demasiadas líneas con el comando `glob`[1] de Python el cual lista reiteradamente el contenido de los directorios de los archivos lo que finalmente termina saturando el nodo destinado para el lanzamiento del programa (ya que recorre la lista de 93 supernovas de HiTS, repitiendo para cada una de ellas el mismo proceso). Por esto último, los administradores del sistema del NLHPC sugirieron modificaciones al programa original, sin embargo, en pos de continuar con el espíritu de esta tesis, se optó por efectuar los experimentos de manera local (usando un computador personal) evitando así introducir más modificaciones (se adaptó el programa para Python 3.5, ya que originalmente estaba para 2.7 agregando cambios menores como la forma de imprimir mensajes en consola (`print`)).

La pipeline original (`candidate_search`) está estructurada, a grandes rasgos por dos bloques de **detección**: el primero está destinado a buscar una supernova confirmada por HiTS (cuya coordenada es conocida) y el segundo a obtener la información de otros posibles candidatos que se hayan encontrado anteriormente. Cabe recalcar que a este segundo proceso se ingresa sólo en el caso que se hayan encontrado candidatos desconocidos en primera fase.

El proceso de búsqueda de la supernova se inicializa en una instancia de RunData, **listando los archivos desde disco**, para preparar las imágenes y el resto de archivos que serán usados para el proceso iterativo siguiente.

[1] https://docs.python.org/3.5/library/glob.html

1. **Cálculo de flujo:** Es el primer paso del ciclo. A partir de las imágenes científicas y de calibración se obtiene el flujo (en ADU[2]) por pixel y es registrado en una matriz (`numpy array`) en cada iteración.

2. **Proceso de estimación con filtro de Kalman:** Corresponde a la segunda etapa del proceso de iteración. En ella se realizan los procesos de predicción y corrección para obtener una nueva estimación.

3. **Detección de fuentes:** El tercer paso del ciclo. En él se estudia la idoneidad de los pixeles tanto del flujo como de las estimaciones del mismo (obtenidos con el filtro de Kalman) y del resto de las imágenes al momento de verificar una serie de criterios con los cuales estos mismos se agruparían entre vecinos para formar potenciales candidatos.

4. **Actualización de candidatos:** Revisa si hay nuevos candidatos a ser considerados. Se registran en un arreglo (`numpy array`).

Si en el proceso anterior se encontró algún candidato, se procede a repetir los pasos de obtención de flujos, estimaciones y filtrado de pixeles. La diferencia está en que en esta oportunidad de van guardando los resultados en una estructura de datos de diccionario. El nuevo ciclo queda como sigue:

1. **Cálculo de flujo:** Repite el primer paso del ciclo descrito anteriormente.

2. **Proceso de estimación con filtro de Kalman:** Repite el segundo paso del ciclo descrito anteriormente.

3. **Detección de fuentes:** Realiza el mismo proceso que el tercer paso del ciclo anterior.

4. **Guardado de resultados:** La información de los nuevos candidatos encontrados previamente es guardado en una estructura de diccionario y registrado en discomo con un formato NPZ (NumPy).

El diagrama de la figura 3.1 entrega una perspectiva general de la secuencia de pasos que realiza el programa.

Cabe destacar que durante el proceso de refactoring del programa original se encontró que la lista de archivos, que debe ser procesada en orden de acuerdo a la época (o fecha de observación) no estaban siendo bien ordenadas durante el proceso de selección de imágenes científicas a partir del valor de `airmass` en la clase FitsHandler.

[2] Analog-to-digital unit

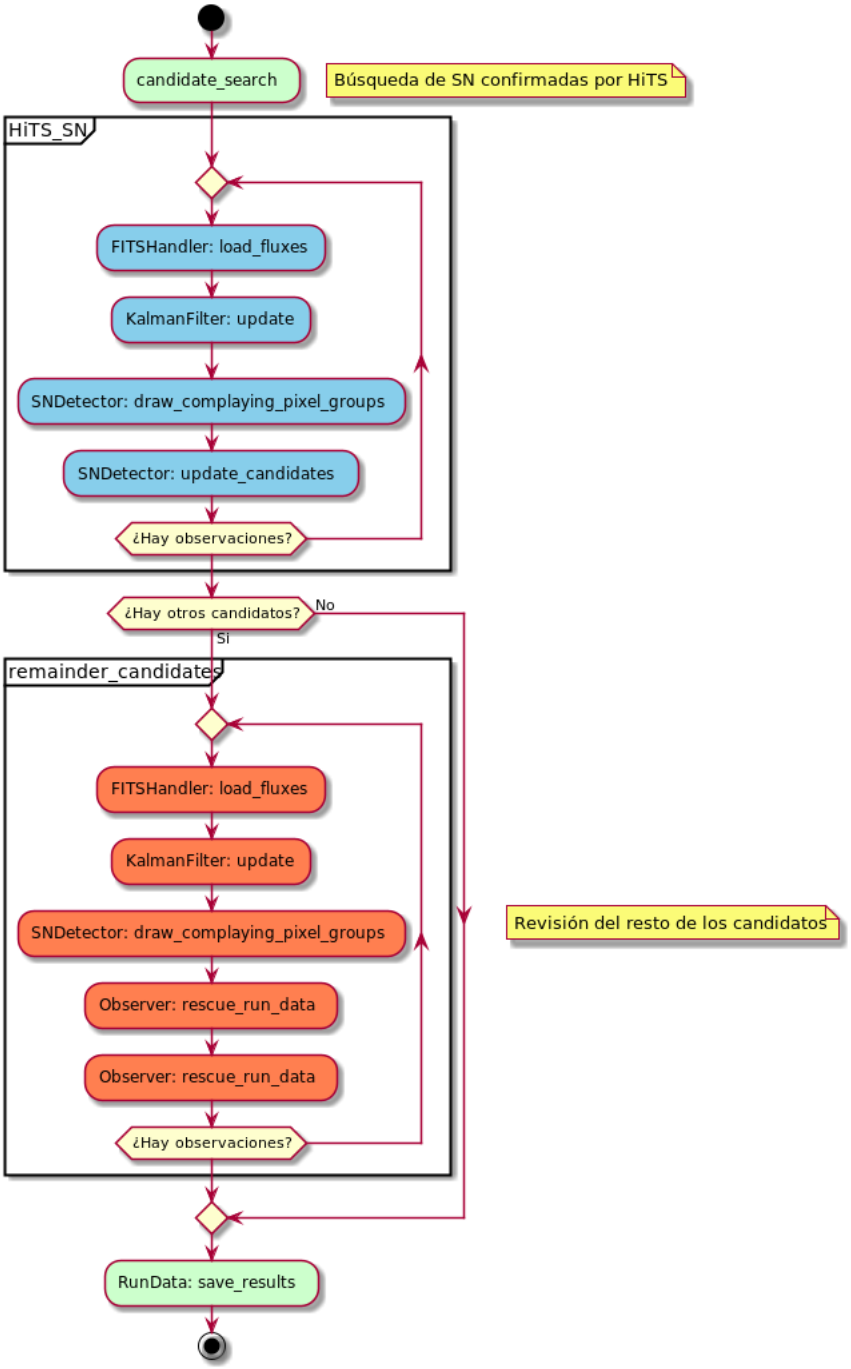

Figura 3.1: Diagrama de actividad del programa original. Se aprecían dos ciclos principales: el primero está destinado a la búsqueda de una supernova de HiTS, y el segundo a la revisión de la lista de posibles candidatos encontrados durante la verificación de la supernova de HiTS. Notar que hay pasos que se repiten en la realización de ambos análisis.

3.1. Tiempo de ejecución

El estudio del tiempo de ejecución del programa se realizó usando la función `getrusage` de la librería `resource` de Python, midiendo el tiempo de usuario en segundos. Las mediciones se

realizaron sobre tres conjuntos de datos (las cuales contienen alguna supernova detectada por HiTS) seleccionados al azar: SN14, SN18 y SN80. En cada uno de ellos comprende secuencias de 26, 23 y 18 observaciones respectivamente.

ID	**Cálc. Flujos** [s]	**Aplic. KF** [s]	**Agrup. Pixeles** [s]	**Actual. Candidatos** [s]
SN14	293.91	24.90	68.30	0.02
SN18	260.09	22.56	45.52	0.00
SN80	204.93	17.69	38.21	0.00
$\bar{t}/Obs$	11.00	0.97	2.24	0.00

Cuadro 3.1: Resultados de tiempos de ejecución correspondientes a calculo de flujos, estimación de los filtros, agrupación de pixeles y filtrado de los mismos durante el periódo de reconocimiento de la supernova correspondiente. Para esta prueba se utilizó el filtro de Kalman Básico. La última fila corresponde a la media por observación.

ID	**Cálc. Flujos** [s]	**Aplic. KF** [s]	**Agrup. Pixeles** [s]	**Guardar resultados** [s]
SN14	303.18	27.28	72.34	0.02
SN18	0.00	0.00	0.00	0.00
SN80	0.00	0.00	0.00	0.00
$\bar{t}/Obs$	11.66	1.05	2.78	0.00

Cuadro 3.2: Resultados de tiempos de ejecución correspondientes a calculo de flujos, estimación de los filtros, agrupación de pixeles y filtrado de los mismos durante el periódo de estudio de los nuevos candidatos encontrados en el paso anterior. Para esta prueba se utilizó el filtro de Kalman Básico. Se observa que para las dos últimas supernovas los tiempos son cero ya que no se encontraron más candidatos.

ID	**Cálc. Flujos** [s]	**Aplic. KF** [s]	**Agrup. Pixeles** [s]	**Actual. Candidatos** [s]
SN14	342.44	798.48	76.47	0.00
SN18	273.64	566.89	47.96	0.00
SN80	210.68	420.12	36.05	0.00
$\bar{t}/Obs.$	12.25	26.23	2.34	0.00

Cuadro 3.3: Resultados de tiempos de ejecución correspondientes a calculo de flujos, estimación de los filtros, agrupación de pixeles y filtrado de los mismos durante el periódo de reconocimiento de la supernova correspondiente. Para esta prueba se utilizó el filtro de Kalman de Máxima Correntropía.

3.2. Uso de memoria

La memoria ocupada por el programa se midió en términos de MiB (Mebibyte) usando la librería `memory_profiler`. Posteriormente las mediciones en la unidad previamente mencionada fueron pasadas a MB[3]

[3] $1MiB \simeq 1.049MB$

ID	**Cálc. Flujos [s]**	**Aplic. KF [s]**	**Agrup. Pixeles [s]**	**Guardar resultados [s]**
SN14	307.64	680.65	65.67	0.02
SN18	0.00	0.00	0.00	0.00
SN80	0.00	0.00	0.00	0.00
$\bar{t}/Obs.$	11.83	26.18	2.53	0.00

Cuadro 3.4: Resultados de tiempos de ejecución correspondientes a calculo de flujos, estimación de los filtros, agrupación de pixeles y filtrado de los mismos durante el periódo de estudio de los nuevos candidatos encontrados en el paso anterior. Para esta prueba se utilizó el filtro de Kalman de Máxima Correntropía. Se observa que para las dos últimas supernovas los tiempos son cero ya que no se encontraron más candidatos.

ID	**Búsqueda SN [s]**	**Revisión candidatos[s]**	**Tiempo total [s]**
SN14	387.13	402.82	789.95
SN18	328.17	0.00	328.17
SN80	260.83	0.00	260.83
$\bar{t}/Obs.$	14.55	–	–

Cuadro 3.5: Tiempo de ejecución de los procesos de búsqueda de supernova de HiTS, revisión de los candidatos encontrados y tiempo total comprendido por ambos procesos usando filtro de Kalman Básico. La última fila corresponde a tiempo total promedio por observación.

ID	**Búsqueda SN [s]**	**Revisión candidatos [s]**	**Tiempo total [s]**
SN14	1217.39	1053.98	2068.80
SN18	888.49	0.00	0.00
SN80	666.85	0.00	0.00
$\bar{t}/Obs.$	40.83	–	–

Cuadro 3.6: Tiempo de ejecución de los procesos de búsqueda de supernova de HiTS, revisión de los candidatos encontrados y tiempo total comprendido por ambos procesos usando filtro de Kalman de Máxima correntropía.

ID	Memoria [MB]
SN14	2282.42
SN18	2063.02
SN80	2021.27

Cuadro 3.7: Memoria principal (en unidades de MB) usada durante la ejecución del programa original usando la versión básica del filtro de Kalman.

ID	Memoria [MB]
SN14	3353.13
SN18	3194.96
SN80	3209.67

Cuadro 3.8: Memoria principal (en unidades de MB) usada durante la ejecución del programa original usando filtro de Kalman de máxima correntropía.

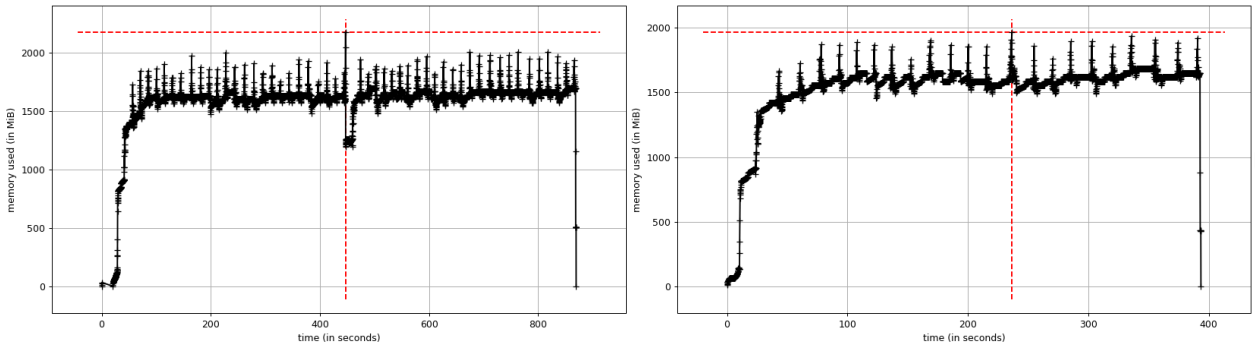

(a) *Memoria ocupada en SN14*

(b) *Memoria ocupada en SN18*

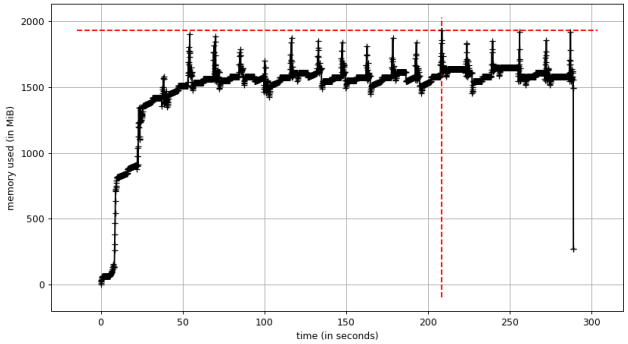

(c) *Memoria ocupada en SN80*

Figura 3.2: Comportamiento de la memoria (en mebibytes) durante la ejecución para los tres conjuntos de datos. En los tres lanzamientos se usó el filtro de Kalman Básico.

3.3. Falsos negativos y verdaderos positivos

La siguiente tabla (3.9), muestra el resultado de la detección de las 93 supernovas de HiTS para el conjunto de datos del año 2015. Esta prueba fue realizada en Leftraru en junio del presente año (previo a cambios introducidos por autor original).

Filtro	**TP**	**FN**
Básico	41	52
MCC	41	52

Cuadro 3.9: Número de falsos negativos y verdaderos positivos encontrados usando cada uno de los filtros. No se observan diferencias sustanciales entre los resultados de cada filtro.

Estableciendo parámetros de umbral de 200.0 para flujo y de 50.0 para la velocidad de flujo (cantidades estimadas por el filtro de Kalman) se obtienen resultados idénticos para ambos filtros al momento de detectar supernovas conocidas por HiTS. En ambos casos se detectaron 41 de 93, lo que da un porcentaje de 44 %.

Sin embargo, cabe destacar que dentro de las 93 supernovas, existen 36 de las cuales se conoce que

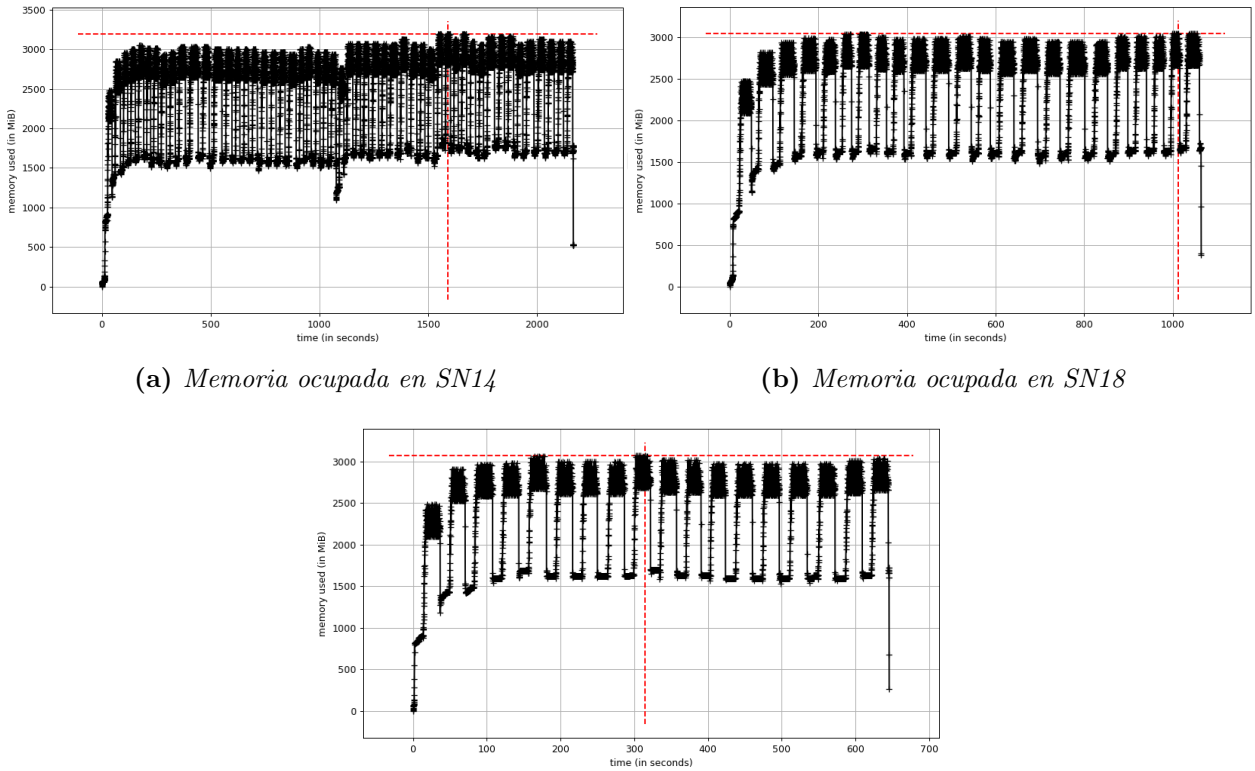

(a) *Memoria ocupada en SN14*

(b) *Memoria ocupada en SN18*

(c) *Memoria ocupada en SN80*

Figura 3.3: Comportamiento de la memoria (en mebibytes) durante la ejecución para los tres conjuntos de datos. En los tres lanzamientos se usó el filtro de Kalman de correntropía máxima.

corresponden a supernovas jóvenes que se encuentran en pleno periodo de aumento de luminosidad (todas del año 2015). De estas 36, para ambos filtros, se detectaron 26 lo que correspondería a un 72 %. Por esta razón se pretende que el desarrollo de un nuevo filtro de aproximación no-lineal podría entregar esperanzas de mejorar este resultado.

3.4. Falsos positivos

El poder reconocer falsos positivos a través de este algoritmo se hace imposible si no se cuenta con una herramienta externa de visualización o de machine learning (por ejemplo, usando un clasificador de conjuntos de pixeles que evalúe la probabilidad de que se trata efectivamente de una supernova joven). Esto se debe a que existen variados objetos como estrellas variables o *artefactos* que corresponden a zonas ruidosas de la imagen científica (en particular, bordes) y pueden proveer valores alterados de flujo lo que en algunos casos puede conllevar a la detección de falsos positivos.

Una forma de poder estudiar un falso positivo es a través de la visualización de su espacio de fase y la obtención de su curva entrópica.

4 | Refactoring

El refactoring del código original se realizó en Python en su versión 3.6.6 (versión diferente a la que el programa fue implementado inicialmente: 2.7). Además se mantuvieron casi la totalidad de las librerías cambiando únicamente Pymorph[1] por Mahotas[2] (ambas librerías desarrolladas por el mismo autor, Luis P. Coelho[3]), debido a que la primera dejó de ser mantenida desde el 2010 y contempla adaptación para Python 3.

4.1. Manejo de datos de entrada

Toda las imágenes de entrada son manipuladas y servidas por la clase DataPicker. Esta clase se inicializa recibiendo un path hacia un archivo de configuración (ver Apéndice B .2) que contiene tanto las rutas a los archivos así como los nombres de estos en términos de expresiones regulares, semestre a los que corresponde la secuencia de observaciones (los dos últimos dígitos del año concatenados con la letra A en caso de corresponder al primer semestre o B al segundo), el campo (representado como un número de dos dígitos, comenzando con cero para valores menores a 10) y el detector CCD (cadena de tres carácteres donde el primero de ellos describe a que grupo de detectores corresponde: N o S (ver figura 2.5); además de un número entero que va de 1 a 36) como strings.

El archivo que esta clase consume, para la configuración de las rutas, debe contener los siguientes campos (ver ejemplo B .2).

- `maskDir`: Directorio donde se almacenan las imágenes máscara (imágenes que identifican píxeles que no deben ser considerados).
- `scienceDir`: Directorio donde se almacenan las imágenes científicas (imágenes base ya preprocesadas).

[1] https://pythonhosted.org/pymorph/
[2] https://mahotas.readthedocs.io/en/latest/
[3] https://github.com/luispedro

- `diffDir`: Directorio donde se almacenan las imágenes de diferencia (resta entre las imágenes base y su científica).
- `psfDir`: Directorio donde se encuentran los modelos de psf (apéndice 1) usados para la determinación del flujo.
- `invDir`: Directorio que guarda las imágenes correspondientes a la varianza inversa (*peso* de cada pixel en términos de ruido: a menor peso, mayor ruido).
- `afluxDir`: Directorio que contiene los archivos de extensión `NPY` dentro de los cuales se guarda el valor de la variable `aflux`.
- `maskRegEx`: Expresión regular con la que es posible identificar el nombre de las imágenes máscara en disco siguiendo el path `maskDir`.
- `scienceRegEx`: Expresión regular con la que es posible identificar el el nombre de las imágenes científicas en disco siguiendo el path `scienceDir`.
- `diffRegEx`: Expresión regular con la que se identifican el nombre de las imágenes de diferencia en disco siguiendo el path `diffDir`.
- `invRegEx`: Expresión regular con la que es posible identificar el nombre de las imágenes de la varianza inversa siguiendo el path `invDir`.
- `afluxRegEx`: Expresión regular con la que se identifica el nombre de los archivos *match* que contienen el valor de `aflux`. Estos archivos están ubicados en el path `afluxDir`.
- `psfRegEx`: Expresión regular que describe el nombre de las imágenes que guardan el modelo de PSF en el directorio `psfDir`.

DataPicker maneja la lectura y preparación de las imágenes a ser analizadas, mientras que un segundo proceso correspondiente a la lectura de resultados anteriores (guardados en un archivo de texto plano) se describirá en el Capítulo 5 de nuevas funcionalidades 5.

4.1.1. Lectura y preparación de imágenes

A continuación se enumeran los diferentes métodos que intervienen en la recolección de los datos a ser leídos:

- `config_reg_expressions(semester, field, ccd)`
  Este método recibe como parámetros el semestre (`semester`), el campo (`field`) y el ccd que

la misma clase recibe de entrada. Con estos strings se establecen las rutas de los directorios de las imágenes y las expresiones regulares de los nombres de las mismas.

- `collect_data()`

  Esta función se encarga de recolectar la ruta completa de las diferentes imágenes (máscarac, científicas, de diferencia, etc.). Para esta finalidad se hace uso del método `walking_through_files`.

- `walking_through_files(regex, dir)`

  Método con el cual se recorren las rutas definidas en los pasos anteriores y se agrupan los nombres completos (directorio incluido) de las imágenes ubicadas en el directorio `dir` y posean un nombre de patrón que siga la expresión regular `regex`.

- `filter_science_images()`

  Filtra imágenes científicas de acuerdo a su airmass 2, seleccionando las fechas en que las observaciones fueron hechas en términos de *día juliano modificado* o *Modified Julian Date* (MJD) como variables de punto flotante.

- `select_fits(dir)`

  Selecciona y ordena los elementos de la lista de imágenes de formato fits del directorio `dir` en orden cronológico (i.e. de acuerdo a la secuencia de MJD encontrada en `filter_science_images()`).

- `select_npys(dir, ref_dir, init_index, n_pos, rest_len)`:

  Selecciona los archivos de extensión NPY que se encuentran en el directorio `dir`. Los nombres son filtrados en relación a las imágenes listadas de `ref_dir` según el paso de `select_fits(dir)` (es decir, debe ser un directorio que contenga imágenes FITS). `init_index`, `n_pos` y `rest_len` son enteros usados para extraer substrings específicos de los nombres de los archivos.

4.2. Determinación de flujos

El proceso de la obtención del flujo se simplificó, eliminando la clase FitsHandler del programa original. Debido a la posibilidad de hacer los métodos de esta clase estáticos se implementó un script Python denominada `utils` para contener estas rutinas e implementarlas estáticamente.

Los métodos que participan en la rutina de calculo de flujo son:

- `naylor_photometry(invvar, diff, psf)` [7]:

  Calcula el producto del flujo por su variaza. Retorna el producto y la varianza. Para esto obtiene el flujo a partir de la imagen PSF entregada (`psf`) y del producto entre la imagen diferencia y la de varianza inverza (`diff` y `invvar` respectivamente).

- `calc_fluxes(diff, psf, invvar, aflux):` Calcula el flujo y su varianza gestionando la entrada y la salida de `naylor_photometry(invvar, diff, psf)`. Los valores NaN son transformados a valores de punto flotante de constante 0.001.

Estos métodos son llamados desde la rutina RoutineHandler (ver en el capítulo 5).

4.3. Filtros originales

La refactorización de los filtros de Kalman originales implicó la implementación de nuevas clases e interfaces para el desarrollo del patrón propuesto: Strategy. A continuación se presentan cada una de ellas:

- **IPredict:** Interface que describe el comportamiento de la función Predict de un filtro de Kalman. `predict` recibe como parámetros el paso de tiempo (Δt), la matriz de estado, la matriz de covarianza de estado, y las predicciones de las matrices de estado y covariaza determinadas en el paso anterior (con la finalidad de actualizar estas variables). Su firma queda como:

  ```
  predict(delta_t, state, state_cov, pred_state, pred_cov)
  ```

  Este método entrega finalmente las matrices de estado y covarianza de estado predicho.

- **ICorrect:** Interface que describe el comportamiento de la función Correct de un filtro de Kalman. `correct` recibe como parámetros el matriz de flujo (`z`) y de varianza de las observaciones (`R`), la matriz de estado predicha, la matriz de covarianza predicha, la matriz de estado y la matriz de covarianza (para sobreescritura) obtenidas en el paso anterior. Su firma queda como:

  ```
  correct(z, R, pred_state, pred_cov, state, state_cov)
  ```

  Esta función entrega finalmente las matrices de estado y covarianza de estado corregido.

4.3.1. Strategies de predicción

LinearPredict: Clase que extiende de IPredict. Implementa método `predict` que será usado tanto por el filtro básico como el de máxima correntropía. Su instanciación recibe como argumento `sigma_a` (desviación estándar del modelo, asumiendo una distribuión gaussiana en la distribución de las observaciones).

4.3.2. Strategies de corrección

BasicCorrect: Clase que extiende de ICorrect. Implementa método `correct` que será usado para el tipo de filtro de Kalman Básico.

MCCorrect: Clase que extiende de ICorrect. Implementa método `correct` que será usado para el tipo de filtro de Kalman de máxima correntropía. El constructor de esta clase recibe los siguientes parámetros:

- `epsilon`: Cantidad con la cual se contrastará el error o precisión que se quiera lograr con la estimación.
- `max_iter`: Número máximo de iteraciones.
- `silverman`: *boolean*. Determina si se usa o no la apoximación de Silverman para la desviación estandar.
- `std_factor`: Factor de desviación estándar usado en la aproximación de Silverman.
- `sigma`: Sigma usado para el kernel Mercer.

4.3.3. Filtros refactorizados

- **KalmanFilter:** Clase abstracta padre de los subtipos BasicKalmanFilter y MCKalmanFilter. Posee los métodos abstractos `predict` y `correct`, que son definidos de acuerdo a las estrategias de predicción y correción descritas previamente.
- **BasicKalmanFilter:** Representa el filtro básico de Kalman. Está compuesto por las estrategias `LinearPredict` y `BasicCorrect`.
- **MCKalmanFilter:** Representa el filtro de máxima correntropía. Está compuesto por las estrategias `LinearPredict` y `MCCorrect`.

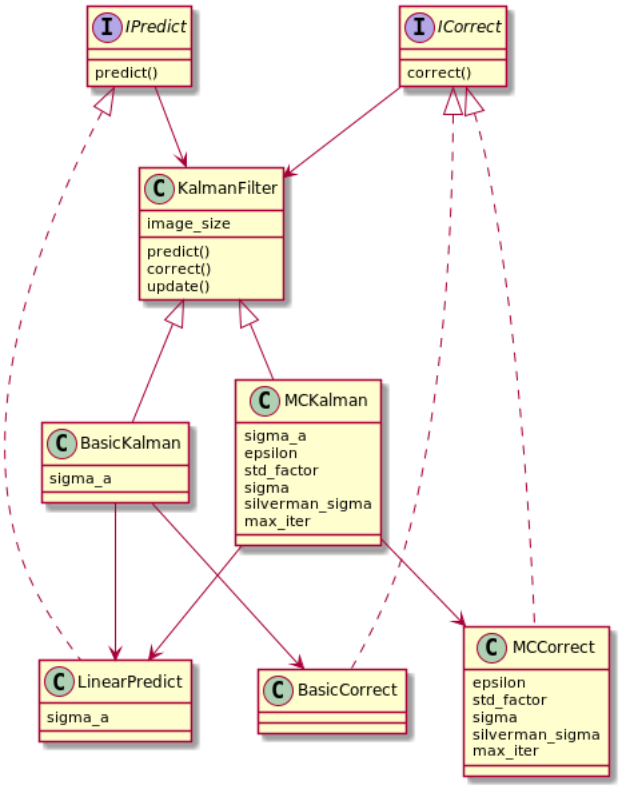

Figura 4.1: Familia de filtros de Kalman y patrón strategy usado en la implementación de los métodos `predict` y `correct`.

4.4. Detección de candidatos

La detección de candidatos en el programa original se realiza en SNDetector sin embargo, durante este refactoring se descompuso el proceso de reconcimiento de fuentes estelares (grupo de pixeles brillantes) del proceso de selección de candidatos, siendo este la continuación del primero. Por tanto se crearon las clases SourceFinder para el filtrado y agrupamiento de pixeles y TP-Detector (transient phenomena detector) para la revisión de las *fuentes* encontradas en el paso anterior.

4.4.1. SourceFinder

La clase SourceFinder posee los siguientes métodos:

- `pixel_discard`:

  Método en el que se realiza el descarte de pixeles de forma individual, siguiendo los siguientes criterios:

  1. Si el estado (flujo) calculado para un pixel es menor que el umbral dado.
  2. Si la tasa de cambio estado (cambio o variación de flujo) es menor que el umbral de

variación de flujo multiplicado por el nivel de saturación alcanzado en esta variación (se define una tasa de saturación *aceptable*).

3. Si un pixel de la imagen científica es menor a la mediana más un valor arbitrario (en este trabajo, siguiendo la línea de desarrollo de P. Huentelemu, se consideró 5.0) es descartado.
4. Si las varianzas de flujo son mayores a 150.0 (valor arbitrario).
5. Si las varianzas de la tasa de cambio de flujo (o velocidad de flujo) es mayor o igual a 150.0.
6. Si los pixeles no caen en etiquetas de invalidación dentro de la máscara que ha sido procesada para marcar también los pixeles vecinos a los realmente defectuosos.
7. Si los pixeles no han caído dentro del descarte por superar la mediana estiamda a partir de cuatro épocas.

- `grouping_pixels(pixel_flags, mjd_index)`:
  Este método recibe como entradas las etiquetas determinadas en el paso anterior en un arreglo de matrices (`numpy array`) denominado `pixel_flags`. Además recibe el índice de MJD (o fecha en día juliano modificado) correspondiente a la observación de tal fecha. La agrupación de pixeles se realiza gracias a funciones brindadas por la librería Mahotas, usando el método `label` para encontrar dominios cerrados en el mapa de pixeles validados.

- `filter_groups(science, flux, var_flux, state, base_mask, median_reject)`:
  Este método recibe la imagen científica, el flujo y su varianza, el estado determinado por el filtro de Kalman, la máscara, y un arreglo en el que se guardan los valores de las medianas por cada cuatro observaciones. El filtrado de grupos de pixeles se lleva a cabo bajo las siguientes reglas de descarte:

  1. Descarte de grupo por contener posible mala resta alrededor (valores negativos).
  2. Si no hay máximos locales dentro del grupo de pixeles encontrados dentro de la imagen científica.
  3. Si no hay máximos locales dentro del grupo de pixeles encontrados dentro de la matriz de flujo.
  4. Si no hay máximos locales dentro del grupo de pixeles encontrados dentro de la matriz velocidad de flujo.
  5. Si los valores de los pixeles superan la mediana local en imagen científica.

6. Si el grupo posee algún pixel que doble el valor del flujo o de la imagen científica.
7. Si el centro del grupo se encuentra etiquetado como defectuoso dentro de la máscara.
8. Si el pixel del centro del grupo se encuentra rechazado al ser superior a la mediana de los pixeles de cuatro observaciones consecutivas.
9. Si la varianza del flujo del pixel del centro del grupo es mayor al determinado por el umbral.

- `draw_complying_pixel_groups`:

  Este método es el que llama a `pixel_discard` para etiquetar pixeles para el descarte y no ser considerados posteriormente en el paso de agrupamiento al llamar a `grouping_pixels`. Luego se llama al método `filter_groups` para hacer el descarte a nivel grupal y obtener candidatos. La última llamada es para el método `save_data` que se encuentra en clase DataContent.

4.5. Visualización de resultados

La visualización de los resultados se realiza a través de la clase **Visualizer** con el cual se generan dos diferentes gráficas usando la librería MatplotLib.

- **Curvas de flujo observado, estimado y predicho, con sus respectivas varianzas**. Otorga información del comportamiento de los flujos de interés durante las diferentes épocas (medidas en MJD).
- **Estampillas**. Se muestra el comportamiento del flujo a través de los pixeles de diferentes matrices: imagen científica, PSF, flujos observado y su varianza, estados de flujo y su velocidad estimados, etiquetas de pixeles y de grupos de pixeles.

Estas gráficas son generadas gracias a los siguientes métodos:

- `plot_lightcurve(coords, position, filename)`:

  Método destinado a crear la serie de curvas de flujo observado, estimado y predicho junto con sus respectivas velocidades de flujo (estimado, predicho) y varianzas. La variable `coords` corresponde a la coordenada del objeto estudiado en la primera imagen científica. La variable `position` guarda la posición del mismo objeto en las estampillas (se asume la misma posición ya que están alineadas). Por último, `filename` corresponde al nombre del archivo con el que se va a guardar la imagen resultante (de extensión PNG, por convención).

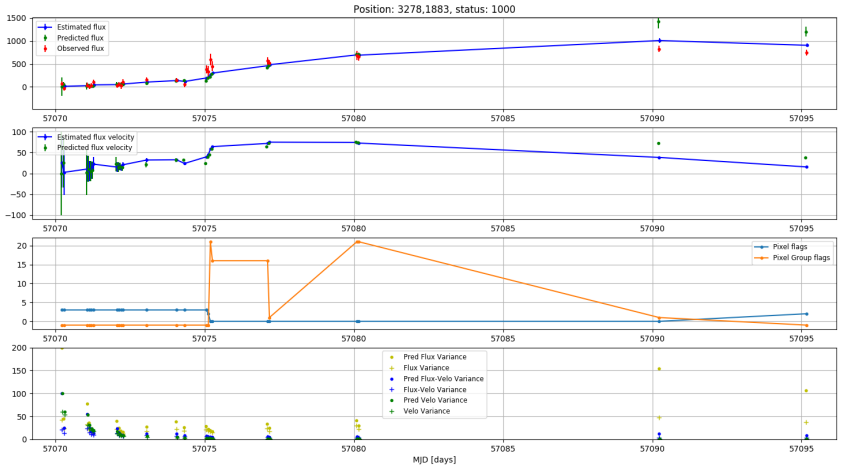

Figura 4.2: Ejemplo de curva de flujo y velocidad de flujo observados, estimados y predichos, de una supernova encontrada por HiTS.

- `print_stamps(coords, filename)`: Recibe el nombre del archivo con el cual se guardará la imagen. Es la función encargada de construir la imagen donde se muestra la evolución de los flujos y las etiquetas de los pixeles en diferentes etapas en las estampillas obtenidas previamente.

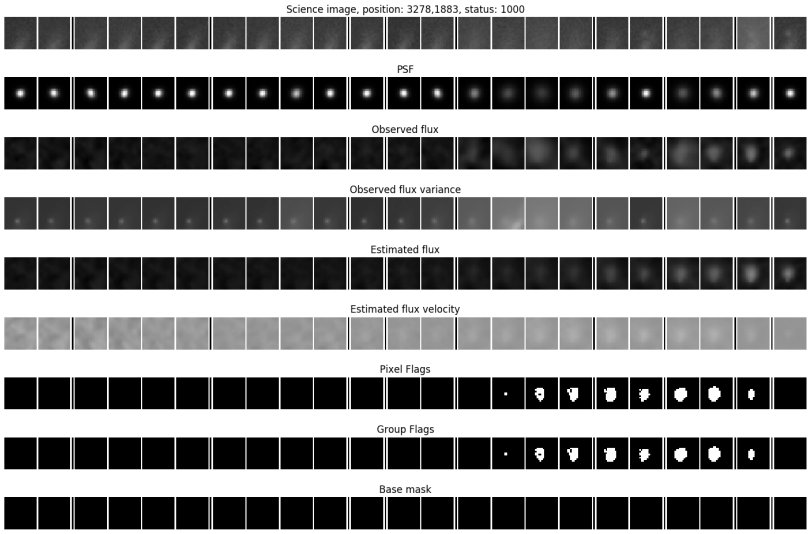

Figura 4.3: Estampillas de matrices de pixeles y etiquetas que muestran el comportamiento del flujo a través del tiempo: la primera fila de imágenes corresponde a estampillas obtenidas desde las imágenes científicas en donde debiese habitar la supernova observada durante todo el periodo de observación (definido por las épocas). La siguiente fila inferior muestra los diferentes modelos de PSF obtenidos para diferentes épocas. La tercera fila muestra el flujo observado en la misma posición. Le sigue la varianza de este flujo. Posteriormente viene el flujo estimado por el filtro de Kalman siguiendo la velocidad de flujo estimado. Finalmente vienen las etiquetas de los pixeles reconocidos por el programa como pertenecientes a un objeto transiente (etiquetado por pixel y pot grupo de pixeles). La última fila corresponde a la máscara base usada en todo el análisis.

5 | Nueva funcionalidad

Se detallan en las siguientes secciones la nueva funcionalidad agregada (no incluye el manejo de los datos en DataPicker ya que se describe como parte del refactoring), con la que se pretende implementar la funcionalidad en línea de este programa.

5.1. Manejo de la rutina: RoutineHandler

La **rutina** se entiende como la ejecución completa del programa, con la cual se procesan todas las observaciones de acuerdo a una lista de CCDs y campos. Para esta finalidad se creó una clase llamada RoutineHandler la cual maneja los archivos de entrada de:

- Lista de campos, CCDs y semestres en un archivo CSV (en este mismo orden) y con el encabezado `Field, CCD, Semester`.
- Diccionario de directorios y expresiones regulares de las ubicaciones de los archivos y sus nombres, respectivamente (archivo TXT).
- Diccionario de umbrales y valores relevantes en la ejecución del programa, así como el tipo de filtro a usar (archivo TXT).

El diccionario de umbrales y valores de configuración contiene la siguiente lista de valores:

- `imgHeight`: Altura de las imágenes científicas.
- `imgWidth`: Ancho de las imágenes científicas.
- `filter`: Tipo de filtro (`basic`, `mcc` o `ukf`).
- `results`: Directorio de resultados (donde guardar estos).
- `init_var`: Varianza inicial que tendran las matrices de covarianza durante el proceso de estimación con los filtros de Kalman.

- `flux_thresh`: Umbral del estado de flujo obtenido con Kalman.
- `flux_rate_thresh`: Umbral de la velocidad de flujo obtenido con Kalman.
- `rate_satu`: Tasa de saturación
- `sigma_a`: Varianza para Kalman Bśico.
- `epsilon`: Radio de error con que la estimación por filtro de Kalman de máxima correntropía disminuye la ganancia de Kalman. Corresponde a un criterio de detención.
- `max_iter`: Número de iteraciones máximo para el proceso de corrección al usar Kalman de máxima correntropía.
- `silverman`: *booleano*. Se establece si se usa o no la aproximación de Silverman para determinar el kernel al emplear el filtro de máxima correntropía.
- `std_factor`: Factor de incremento de sigma al usar el método de Silverman.
- `sigma`: Sigma usado por defecto, sin Silverman, en la determinación del kernel durante el proceso de corrección con el Filtro de Kalman de máxima correntropía.

Esta clase contiene los siguientes métodos:

- `process_settings()`:
  En este método se lee el archivo de diccionario de umbrales y valores con los que se configurará la toma de decisiones del programa.

- `retrieve_kalman_filter(kalman_string)`:
  Corresponde a un método auxiliar que es invocado desde `process_settings` con el que se crea una instancia del filtro de Kalman a partir de la lectura del archivo de valores, de acuerdo al valor defindo por el usuario. Los tres strings válidos para la construcción de una instancia son: 'Basic', 'MCC' y 'UKF'. Si se entrega otro tipo de string, se levanta un error.

- `iterate_over_sequences()`:
  Recorre la lista de campos, CCDs y semestres entregada al programa con la consiguiente llamada a `routine`

- `routine(semester, field, ccd, results_path, last_mjd)`:

  Corresponde a la rutina que comprende el análisis de las observaciones de un semestre, campo y CCD específico.

5.2. Detección de fenómenos trasientes: TPDetector

Es una pequeña clase con la que se apoya el proceso de reconocimiento o detección de algún fenómeno trasiente en el comportamiento de la intensidad de los pixeles calculados después la ejecución de `routine` (es decir, una vez que se han obtenido los resultados con `routine` de RoutineHandler).

Esta clase posee los siguientes métodos:

- `look_candidates(results_path, field, ccd, semester)`:

  Con este método se agrupan los resultados obtenidos por campo, CCD y semestre en la ruta de los resultados (`results_path`), y carga los arreglos de los candidatos encontrados (de acuerdo a su coordenada central) y cuenta las veces que aparece cada uno en los archivos (un archivo por época u observación) con la finalidad de registrar *las veces que ha sido candidato.*

- `list_candidates(cand_mid_coords)`

  Con finalidades exploratorias, este método registra los candidatos (por pares de pixeles que describen el centro de los grupos encontrados) sin repetición, independiente de las veces que han aparecido.

5.3. DataContent

DataContent es una clase auxiliar que es usada principalmente para encapsular los resultados obtenidos durante el proceso de detección, tanto de los pixeles de los grupos encontrados por época, la lista de pixeles centrales de estos grupos, las matrices de etiquetas (para realizar seguimiento de las causas del descarte de los pixeles o grupo de pixeles), así como también los estados encontrados por el filtro usado. Para guardar estos resultados se utiliza la función `savez` de la librería Numpy, los archivos guardados son registrados en un archivo de extensión NPZ.

Para el guardado de los datos se implementó la función `save_results` que recibe como parámetros la ruta donde se quiere almacenar los resultados, el campo de observación, el CCD, el MJD y la matriz de estados junto con la covarianza de estados. El resto de los arreglos son definidos en las funciones `set_mid_coords` y `group_info`.

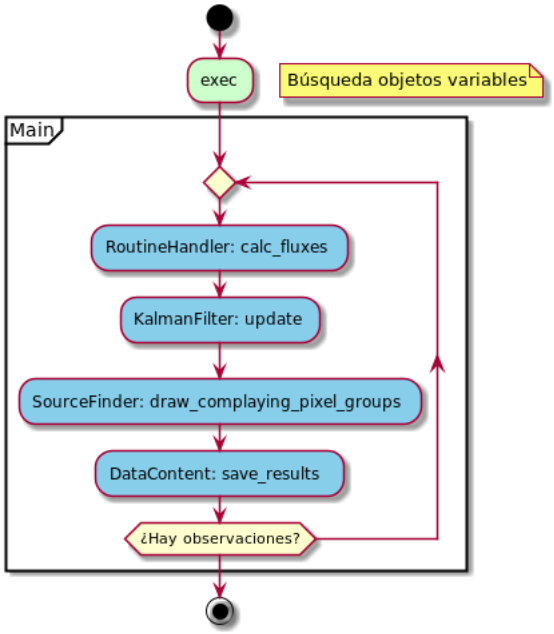

Figura 5.1: Rutina del programa refactorizado.

5.4. Nuevo método en Visualizer

Se implementó una nueva función con la que visualizar el espacio de fase del flujo y su velocidad estimada.

```
print_space_states(coords, position, save_filename)
```

Esta función recibe como entradas la coordenada del objeto, la posición en estampillas determinadas anteriormente (para no cargar todas las matrices de estado y covarianza en memoria) y un nombre de archivo en `file_name`.

5.5. Filtro de Kalman Unscented

El diseño de la nueva clase de filtro se realizó continuando con la arquitectura del patrón Strategy, definiendo los métodos de predicción y corrección en instancias de clases que implementen las interfaces IPredict e ICorrect respectivamente: UnscentPredict y UnscentCorrect.

5.5.1. La clase UnscentKalman

El filtro Unscented se desarrolló en la clase UnscentKalman, la cual encierra los métodos de predicción y corrección (descritos en el Capítulo 2, subsección 2.3.3) implementados en `predict` y `correct`.

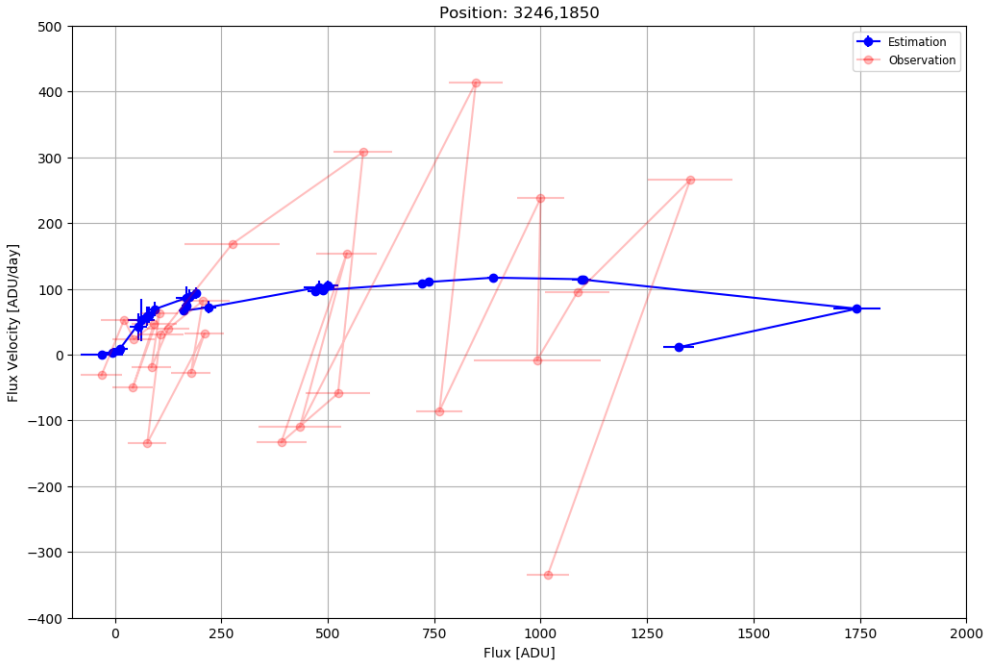

Figura 5.2: Espacio de fase de flujo y velocidad de flujo. En azul se destaca la estimación lograda por filtro de Kalman. En rojo, corresponde al comportamiento del flujo observado y su varianza. Se destaca la curva final de los estados estimados ya que esta da cuenta el alcance máximo en la curva de la supernova y su próximo decaimiento.

La generación de una instancia de esta clase requiere como argumentos de entrada los siguientes parámetros:

- `f_func:` Función usada para obtener el primer conjunto de puntos sigma para el periodo de predicción. Consiste en una función vectorial que se aplica sobre cada elemento de una matriz cuya dimensión es la misma que la de la matriz de estado.
- `h_func:` Función usada para obtener el segundo conjunto de puntos sigma durante el proceso de corrección. Su aplicación procede de la misma forma que la descrita para `f_func`.
- `alpha:` Término que indica que tan separados se encuentran los puntos sigma en torno a la media. Por lo general su valor oscila entre 10^{-4} y 1.
- `beta:` Describe el valor de *beta* el cual incorpora conocimiento *a priori* sobre la distribución de las variables de estado. Para distribuciones gaussianas, tiene un valor de $\beta = 2$.
- `kappa:` Corresponde a un parámetro de escalamiento secundario. Su valor va entre 0 y $3 - N$.
- `image_size:` Dimensiones de la imagen de flujo.

Al inicializar una instancia de esta clase, se calculan tanto los pesos como el término *lambda*, los cuales dependen de los parámetros: β, κ α y N o cantidad de variables de estado (ver Ecuaciones 2.24 y 2.25).

Como parte de la familia de KalmanFilter posee el método `update`, desde el cual se llama a `predict` y a `correct`, conservando la firma.

5.5.2. Predicción

La predicción de este filtro se implementó, como se mencionó anteriormente, en la clase UnscentPredict (que implementa IPredict). Para instanciar esta clase se debe entregar como argumento al constructor: un puntero a función (que puede o no ser lineal), los pesos asociados a la media y la covarianza de predicción, el coeficiente λ, y la dimensión de las variables de estados (en este modelo, se trata de dos: flujo y velocidad de flujo). Por lo tanto la firma del constructor queda como sigue:

```
UnscentPredict(f_func, Wm, Wc, lambda_, N)
```

donde `f_func` corresponde a la función con la cual se quiere modelar el comportamiento del flujo; `Wm` y `Wc` corresponden a los pesos de la media y covarianza respectivamente (obtenidos externamente), `lambda_` y `N` correspondiente al número de variables de estado.

Se destaca que tantos los pesos como el valor de λ se mantienen constantes durante todo el proceso de estimación. Por otro lado, en el mismo método, se calculan los *puntos sigma* (ver Ecuación 2.22) los cuales, para su determinación requieren los pesos y del valor de λ, además de la función f (entregada como `f_func`) para evaluar en los puntos sigma.

La salida de este método está compuesta por la matriz de estado predicha, la predicción de la covarianza y los puntos sigma guardados en la variable `Xs` de la implementación.

5.5.3. Corrección

El proceso de corrección está implementado en la clase UnscentCorrect la cual implementa la interfaz ICorrect redefiniendo el método `correct`. Al venir de la misma familia, este método conserva siempre su firma.

Durante la corrección se escogen nuevamente $2N + 1$ puntos sigma en torno al estado predicho (fase previa) (ver Ecuación 2.28), sin embargo los valores de los pesos y de λ son los mismos usados

durante la fase de predicción, cambiando sólo la función que se propaga sobre este nuevo conjunto de puntos: $h(\dot{})$ (expresada como `h_func`).

5.5.4. Funciones auxiliares

Se desarrollaron diferentes funciones auxiliares para apoyar el cálculo de las matrices:

- `sigma_points(mean_, cov_, lambda_, N):`
  Función con la cual se calculan los puntos sigma a partir la media de las variables de estado, la covarianza, el valor de λ y el número de variables de estado, N. Utiliza para esta finalidad, la descomposición de Cholesky.

- `unscent_weights(kappa, alpha, beta, N):`
  Método con el que se calculan los pesos a partir de los valores de κ, α, β y N (número de variables de estado).

- `perform(func, *args):`
  Función auxiliar con la cual se recibe un puntero a otra función vectorial (destinada a ser aplicada sobre un conjunto de puntos sigma) y un número arbitrario de argumentos, dependiendo de la necesidad de la misma función

- `propagate_func(func, Wm, Wc, Xs, *args, N):`
  Función con la que se propaga la función `func` sobre el conjunto de puntos sigma `Xs` usando los pesos de media y covarianza `Wm` y `Wc`, respectivamente, además del número de variables de estado, N. Además, recibe el argumento `args` que corresponde a una tupla de entradas propias de la función `func`.

- `matrix_inverse(M):`
  Calcula la inversa de una matriz siguiendo la estructura de datos descrita en el Capítulo 3.

- `matrix_vector_dot_product(M, v):`
  Función auxiliar para el cálculo del producto punto entre una matriz (cuya dimensión es la de una matriz de covarianza definida en el Capítulo 3) y un *vector* de las dimensiones de una matriz de estado (ver mismo capítulo).

Estas funciones están implementadas en el script `unscented_utils`.

6 | Resultados

6.1. Desempeño

En esta sección se describen los resultados obtenidos durante las experiencias de medición de desempeño de la nueva versión del programa en términos de tiempo y memoria principal usada.

Las pruebas se realizaron usando el mismo conjunto de datos utilizado para medir el desempeño del programa original 3, además se emplearon como herramientas de medición igualmente el perfilador de memoria `mem_profiler` y la librería RESOURCE[1].

6.1.1. Filtros básico y de máxima correntropía

Los cuadros 6.1 y 6.4 muestran los resultados de tiempo medido en segundos de cada una de las partes del proceso de la rutina principal, para los tres datasets usando los filtros básico y de máxima correntroía, respectivamente. Posteriormente, los cuadros 6.2 y 6.5 resumen la totalidad de tiempo usado durante la ejecución (para ambos filtros). A todos estos resultados se les ha agregado la medición de tiempo promedio utilizado por imagen (ya que las secuencias poseen largos diferentes).

ID	**Cálc. Flujos** [s]	**Aplic. KF** [s]	**Agrup. Pixeles** [s]	**Obt. Candidatos** [s]
SN14	285.81	22.45	65.18	0.00
SN18	253.19	20.08	65.67	0.00
SN80	228.60	26.06	67.77	0.00
$\bar{t}/Obs$	11.57	1.06	3.04	0.00

Cuadro 6.1: Tiempo de ejecución en segundos de cada proceso involucrado, usando el filtro de Kalman básico refactorizado: cálculo de flujo estimación de filtros, agrupación de pixeles y obtención de candidatos (operación que involucra guardado de los mismos). La última fila describe el tiempo promedio que toma por observación (en segundos igualmente) para cada uno de los procesos.

[1] Método `get_rusage`

ID	Tiempo total
SN14	373.44
SN18	338.94
SN80	322.43
$\bar{t}/Obs.$	15.67

Cuadro 6.2: Tiempo de ejecución de los procesos de búsqueda de supernova de HiTS, revisión de los candidatos encontrados y tiempo total comprendido por ambos procesos usando filtro de Kalman Básico refactorizado. La última fila corresponde a tiempo total promedio por observación.

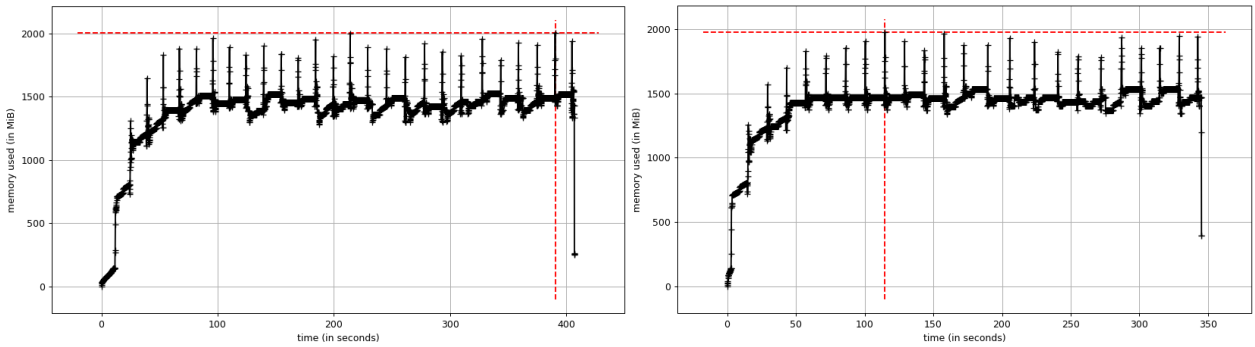

(a) *Memoria ocupada en SN14*

(b) *Memoria ocupada en SN18*

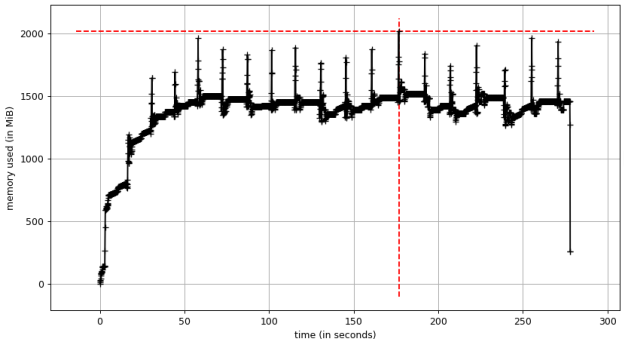

(c) *Memoria ocupada en SN80*

Figura 6.1: Comportamiento de la memoria (en mebibytes) durante la ejecución para los tres conjuntos de datos. En los tres lanzamientos se usó el filtro de Kalman Básico.

ID	Memoria [MB]
SN14	2098.00
SN18	2066.72
SN80	2119.24

Cuadro 6.3: Memoria principal (en unidades de MB) usada durante la ejecución del programa refctorizado usando filtro de Kalman Básico.

ID	Cálc. Flujos [s]	Aplic. KF [s]	Agrup. Pixeles [s]	Actual. Candidatos [s]
SN14	284.99	529.68	54.86	0.00
SN18	256.58	507.46	66.73	0.00
SN80	209.02	411.94	45.94	0.00
$\bar{t}/Obs$	11.00	0.97	2.24	0.00

Cuadro 6.4: Tiempo de ejecución en segundos de cada proceso involucrado, usando el filtro de Kalman de máxima correntropía refactorizado: cálculo de flujo estimación de filtros, agrupación de pixeles y obtención de candidatos (operación que involucra guardado de los mismos). La última fila describe el tiempo promedio que toma por observación (en segundos igualmente) para cada uno de los procesos.

ID	Tiempo total
SN14	869.53
SN18	830.77
SN80	666.90
$\bar{t}/Obs.$	35.54

Cuadro 6.5: Tiempo de ejecución de los procesos de búsqueda de supernova de HiTS, revisión de los candidatos encontrados y tiempo total comprendido por ambos procesos usando filtro de Kalman de máxima correntropía refactorizado. La última fila corresponde a tiempo total promedio por observación.

ID	Memoria [MB]
SN14	3164.83
SN18	3186.06
SN80	3154.98

Cuadro 6.6: Memoria principal (en unidades de MB) usada durante la ejecución del programa refactorizado usando filtro de Kalman de máxima correntropía.

6.1.2. Filtro unscented

6.2. Pruebas en Leftraru

6.2.1. Filtro básico

6.2.2. Filtro de máxima correntropía

6.2.3. Filtro unscented

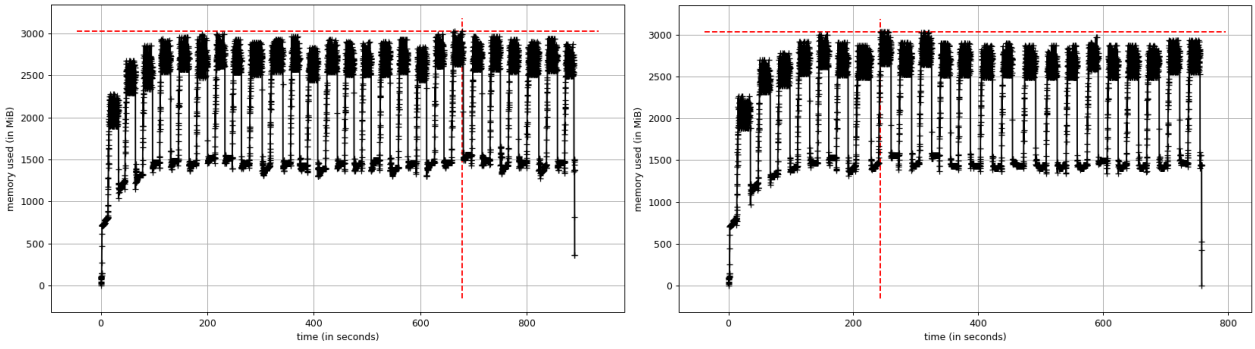

(a) *Memoria ocupada en SN14*

(b) *Memoria ocupada en SN18*

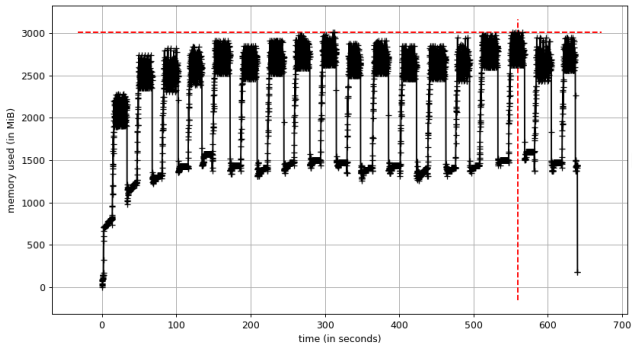

(c) *Memoria ocupada en SN80*

Figura 6.2: Comportamiento de la memoria (en mebibytes) durante la ejecución para los tres conjuntos de datos. En los tres lanzamientos se usó el filtro de Kalman de máxima correntropía.

7 | Conclusiones

7.1. Trabajo futuro

El trabajo propuesto en esta tesis describe tres diferentes versiones de un nuevo método de detección de fenómenos trasientes en régimen creciente, basados tres variantes del filtro de Kalman, destinado a la detección de supernovas en etapa temprana. Sin embargo este mismo método puede ser aplicado en la detección de estrellas variables usado un filtro que distinga tendencias decrecientes en la luminosidad de estos objetos; por lo que una extensión prometedora de este sistema podría diseñarse para reconocer alternancia en los regímenes creciente y decreciente, haciendo uso de la estructura de clases dada por el patrón Strategy en el modelo del filtro.

Por otro lado queda también pendiente, el estudiar el comportamiento de los resultados al variar los umbrales relacionados con la estimación realizada por el filtro de Kalman y que son usados en la fase de reconocimiento de candidatos (en la clase SourceFinder). [Método basado en machine learning para estudiar falsos positivos??]

Capítulo Adicional que no es apéndice

Apéndices

A . Glosario

1. **PSF**

   Corresponde a la respuesta instrumental a una fuente de luz puntual, cuya radiación debe atravesar la atmósfera terrestre y los lentes del telescopio. La distorsión puede ser interpretada como la convolución de la imagen por un kernel. [8]. Ver imagen 7.1

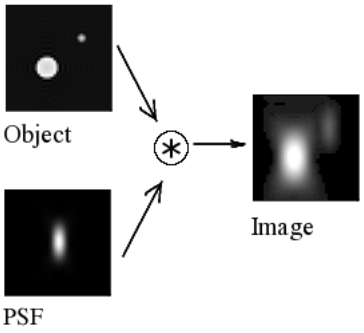

Figura 7.1: Ejemplo de distorsión de una fuente al aplicar un kernel de PSF específico. El resultado se observa en el cuado *Image*.

2. **Airmass**

   Es el largo del camino de que le toma a los rayos de una cuerpo celeste atravesar la atmósfera. A medida que los rayos van penetrando la atmósfera estos se van atenuando por la absorción y el proceso conocido como scattering.

3. **Fotometría de Naylor**

B . Refactoring

B .1. Librerías usadas para el refactoring

Versión de Python: 3.5

- `pandas`: **0.24.4**
- `matplotlib`: **2.2.2**
- `numpy`: **1.13.3**
- `mahotas`: **1.4.4**
- `astropy`: **3.0.2**

B .2. Archivo de entrada: configuración de paths

```
maskDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s
scienceDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s
diffDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s
psfDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s/CALIBRATIONS
invDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s
afluxDir = /home/paloma/Documents/Memoria/data/Blind%s_%s/%s/CALIBRATIONS
maskRegEx = Blind%s_%s_%s_[0-9][0-9]_dqmask.fits.fz
scienceRegEx = Blind%s_%s_%s_[0-9][0-9]_image_crblaster_grid02_lanczos2.fits
diffRegEx = Diff_Blind%s_%s_%s_[0-9][0-9]t*-0[0-9]t*_grid02_lanczos2.fits
invRegEx = invVAR_Blind%s_%s_%s_[0-9][0-9]t*-0[0-9]t*_grid02_lanczos2.fits
afluxRegEx = match_Blind%s_%s_%s_[0-9][0-9]-0[0-9].npy
psfRegEx = psf_Blind%s_%s_%s_[0-9][0-9]t*-0[0-9]t*_grid0[1-2]_lanczos2.npy
```

C . Nueva funcionalidad

C .1. Modelo de archivo de almacenamiento de resultados

D . Unit-tests

D .1. Refactoring

- `test_input`

  Comprueba que outputs generados de la lectura de los datos de la nueva versión del programa sea identica a los generados por el código original. Esto se logra siguiendo el proceso de filtrado de imágenes científicas por airmass con la consiguiente secuenciación cronológica (en términos de MJD) del resto de las imágenes.

- `test_flux`

  Prueba el correcto funcionamiento de `calc_flux` mediante comparación de outputs de versión original y nueva.

- `test_basicKF`

  Comprueba que las salidas de la versión bśica del filtro de Kalman del programa refactorizado sea idéntico al de la versión original, usando secuencia de imágenes conocida.

- `test_MCKF`

  Comprueba que las salidas de la versión de máxima correntroía del filtro de Kalman del programa refactorizado sea idéntico al de la versión original, usando secuencia de imágenes conocida.

Referencias

[1] B. Chen, X. Liu, H. Zhao, and J. C. Príncipe. Maximum Correntropy Kalman Filter. *ArXiv e-prints*, Sept. 2015.

[2] B. Chen, X. Liu, H. Zhao, and J. C. Principe. Maximum correntropy kalman filter. *Automatica*, 76:70 – 77, 2017.

[3] F. Forster, J. C. Maureira, S. Gonzalez-Gaitan, G. Medina, G. Pignata, L. Galbany, J. San Martin, M. Hamuy, P. Estevez, R. C. Smith, K. Vivas, S. Flores, P. Huijse, G. Cabrera, J. Anderson, F. Bufano, T. de Jaeger, J. Martinez, R. Munoz, E. Vera, and C. Perez. HiTS real-time supernova detections. *The Astronomer's Telegram*, 7146, Feb. 2015.

[4] B. J Mercer. Xvi. functions of positive and negative type, and their connection the theory of integral equations. *Phil. Trans. R. Soc. Lond. A*, 209(441-458):415–446, 1909.

[5] R. E. Kalman. A New Approach to Linear Filtering and Prediction Problems. *Transactions of the ASME - Journal of Basic Engineering*, 82:35–45, 1960.

[6] A. P. A. LSST Science Collaboration, A. J., and A. S. F. et al. *LSST Science Book, Version 2.0*. arXiv:0912.0201, 2009.

[7] T. Naylor. An optimal extraction algorithm for imaging photometry. *Monthly Notices of the Royal Astronomical Society*, 296(2):339–346, 1998.

[8] H. P. Filtro de Correntropía para detección de supernovas. *Tesis de magíster en ciencias de la ingeniería, mención eléctrica de la Universidad de Chile, Facultad de Ciencias Físicas y Matemáticas*, 2016.

[9] E. A. Wan and R. Van Der Merwe. The unscented kalman filter for nonlinear estimation. In *Adaptive Systems for Signal Processing, Communications, and Control Symposium 2000. AS-SPCC. The IEEE 2000*, pages 153–158. Ieee, 2000.